

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMATIKOS INSTITUTAS
PROGRAMŲ SISTEMŲ SPECIALYBĖ

Bakalauro darbas

**QNLP modelio taikymas ekstraktyvaus tekstų santraukų
sudarymui**

(Application of a QNLP Model to Extractive Text Summarization)

Atliko: 4 kurso 3 grupės studentas

Naglis Kontautas (parašas)

Darbo vadovas:

lekt. Irus Grinis (parašas)

Vilnius
2026

Turinys

Santrauka	3
Summary	4
Sąvokų apibrėžimai	5
Įvadas	7
1. DisCoCat modelis ir semantinė vektorinė kompozicija	9
1.1. Kombinatorinė kategorinė gramatika	10
1.2. DisCoCat funkcinės kategorijos	10
2. Duomenų rinkinio sudarymas	14
2.1. Duomenų rinkinio pasirinkimo kriterijai	14
2.2. Pirminis duomenų rinkinio pasirinkimas: CNN/DailyMail ir PreSumm.....	14
2.3. WikiHow duomenų rinkinys.....	15
2.4. Sakinių etikečių sudarymas naudojant TransformerSum.....	16
2.5. Mokymo ir validavimo bei testavimo rinkiniai	16
2.5.1. Top-ratio	16
2.5.2. z-įvertis	16
2.6. Gautas duomenų rinkinys	17
3. Duomenų transformavimo veiksmai	18
3.1. Sakinių supaprastinimas	18
3.2. Sakinių transformavimas į diagramas	19
3.3. Diagramų normalizavimas ir perrašymas	20
3.4. Kvantinių grandinių generavimas	21
3.4.1. Kvantinių bitų paskirstymo žemėlapis	22
3.4.2. Parametrizuotos kvantinės grandinės generavimas	22
3.5. Kvantinių grandinių filtravimas	23
4. Kvantinis modelis	25
4.1. Modelio realizacija naudojant NumpyModel	25
4.2. Modelio išvestis ir sakinio klasifikavimas	25
4.3. TketModel ir AerSimulator atsisakymo pagrindimas	26
5. Modelio mokymas	27
5.1. Modelio paruošimas mokymui	27
5.2. Mokymo ir vertinimo duomenų rinkiniai	28
5.3. Mokymo konfigūracija	28
5.4. Nuostolio funkcija.....	29
5.5. Optimizavimo metodas	30
5.6. Vertinimo eiga.....	31
5.7. Vertinimo metrikos.....	31
6. Ekperimentų rezultatai	33
6.1. Vieno kubito modelių mokymo rezultatai	34
6.1.1. Modelis vol.1.1.2	34
6.1.2. Modelis vol.1.2.2	37
6.1.3. Modelis vol.1.3.3.1.2	40
6.2. Dviejų kubitų konfigūracijos modelio mokymo rezultatai	43
6.2.1. Modelis ver.2.1.1.1	43
6.3. TketModel bandymas	47
Rezultatai	49
Išvados	50

Literatūra	52
Priedas Nr. 1. Darbo programinio kodo ir vykdymo aplinkos nuorodos	53

Santrauka

Šiame darbe nagrinėjamas kvantinio natūralios kalbos apdorojimo modelio taikymas ekstraktyvaus tekstų santraukų sudarymo uždaviniui. Darbo tikslas – įvertinti *lambeq* pagrindu sudaryto QNLP modelio pritaikomumą sakinių klasifikavimo uždaviniui ir nustatyti pagrindinius praktinius tokio metodo apribojimus. Ekstraktyvus santraukų sudarymas darbe formuluojamas kaip dvejetainė sakinių klasifikacija, kurioje kiekvienam sakiniui nustatoma, ar jis turėtų būti įtrauktas į santrauką.

Tyrimui sudarytas sakinių lygmens duomenų rinkinys, pagrįstas *WikiHow* teksta ir silpnos priežiūros principu sugeneruotomis etiketėmis. Sakiniai buvo sintaksiškai supaprastinti, transformuoti į gramatines diagramas, o vėliau – į parametrizuotas kvantines grandines. Modelio mokymas atliktas naudojant *lambeq* bibliotekos *QuantumTrainer* ir *NumpyModel*. Taip pat atliktas pradinis *TketModel* ir *AerSimulator* bandymas, kuris parodė mėginių vykdymu pagrįsto metodo nestabilumą šiame uždavinyje.

Eksperimentų metu tirta kelių modelio konfigūracijų įtaka rezultatams, įskaitant skirtingą *AtomicType.NOUN* tipui priskirtų kubitų skaičių. Gauti rezultatai parodė, kad QNLP modelį galima techniškai pritaikyti sakinių klasifikavimo uždaviniui, tačiau klasifikavimo kokybė išliko ribota ir bendras modelio veikimas dar nebuvo pakankamas praktiniam ekstraktyvaus santraukų sudarymo taikymui. Darbe nustatyta, kad pagrindiniai metodo apribojimai yra susiję su kvantinių grandinių sudėtingumu, duomenų paruošimu, simuliacijos stabilumu ir modelio gebėjimu išlaikyti mokyme pasiektą kokybę testavimo rinkinyje.

Raktiniai žodžiai: kvantinis natūralios kalbos apdorojimas, QNLP, ekstraktyvus santraukų sudarymas, sakinių klasifikavimas, kvantinio modelio mokymas, *lambeq*, parametrizuotos kvantinės grandinės.

Summary

This thesis investigates the application of a quantum natural language processing model to extractive text summarization. The aim is to evaluate the applicability of a QNLP model built with *lambeq* to a sentence classification task and to identify practical limitations of this approach. In this work, extractive summarization is formulated as a binary sentence classification problem, where each sentence is classified as either suitable or not suitable for inclusion in a summary.

A sentence-level dataset was constructed using *WikiHow* texts and weakly supervised labels generated with a pre-trained extractive summarization model. The sentences were syntactically simplified, transformed into grammatical diagrams, and then converted into parameterized quantum circuits. The model was trained using `QuantumTrainer` and `NumpyModel` from *lambeq* library. An initial experiment with `TketModel` and `AerSimulator` was also performed, showing that the shot-based execution scenario was unstable for this task.

The experiments evaluated several model configurations, including different numbers of qubits assigned to the `AtomicType.NOUN` type. The results showed that a QNLP model can be technically applied to the sentence classification task, but the classification performance remained limited and the overall performance was insufficient for practical extractive summarization. The study identified several major limitations of the method, including the complexity of generated quantum circuits, dataset preparation constraints, simulation stability issues, and limited model generalization.

Keywords: quantum natural language processing, QNLP, extractive summarization, sentence classification, quantum model training, *lambeq*, parameterized quantum circuits.

Sąvokų apibrėžimai

Natūralios kalbos apdorojimas (NLP). Kompiuterinių metodų visuma, skirta žmogaus kalbai analizuoti, apdoroti ir generuoti.

Kvantinis natūralios kalbos apdorojimas (QNLP). Natūralios kalbos apdorojimo kryptis, kurioje kalbos struktūros modeliuojamos naudojant kvantinio skaičiavimo principus arba kvantinių grandinių reprezentacijas.

Ekstraktyvi santrauka. Santrauka, sudaroma atrenkant originalaus teksto sakinius ar fragmentus jų neperrašant.

Abstraktyvi santrauka. Santrauka, kurioje originalaus teksto turinys perteikiamas naujai sugeneruotu tekstu.

Duomenų rinkinys. Struktūruota duomenų visuma, naudojama modelio mokymui, validavimui arba testavimui.

Kombinatorinė kategorinė gramatika (CCG). Gramatikos formalizmas, kuriame žodžiams ir frazėms priskiriamos kategorijos, nusakančios jų jungimosi su kitomis kategorijomis taisykles.

DisCoCat. Kompozicinės semantikos modelis, jungiantis paskirstytas žodžių reikšmių reprezentacijas su gramatine sakinio struktūra.

Gramatinė diagrama. Sakinio struktūros reprezentacija diagrama, kurioje žodžiai vaizduojami kaip dėžutės, o gramatiniai ryšiai – kaip vielos.

lambeq. Python biblioteka, skirta gramatinėms diagramoms generuoti, perrašyti ir transformuoti į parametrizuotas kvantines grandines.

DepCCGParser. *lambeq* naudojamas analizatorius, kuris sakiniams priskiria CCG tipo gramatinę struktūrą ir leidžia ją paversti diagrama.

spaCy. Python biblioteka, skirta natūralios kalbos apdorojimo užduotims, šiame darbe naudota sakinių priklausomybių analizei ir sintaksiniam supaprastinimui.

IQP ansatz. Parametrizuotas kvantinių grandinių šablonas, naudojamas gramatinėms diagramoms paversti kvantinėmis grandinėmis.

Kubitas. Kvantinės informacijos vienetas, galintis būti superpozicijos būsenoje.

Kvantinė grandinė. Kvantinių vartų seka, taikoma kubitams, siekiant atlikti kvantinį skaičiavimą arba simuliaciją.

Kvantiniai vartai. Operacijos, keičiančios vieno arba kelių kubitų būseną kvantinėje grandinėje.

Kvantinės grandinės gylis. Nuoseklių operacijų sluoksnių skaičius kvantinėje grandinėje.

Mėginių simuliacijos. Kvantinės grandinės vertinimo būdas, kai grandinė vykdoma daug kartų ir iš gautų matavimo rezultatų sudaromas statistinis įvertis.

Tikslusis simuliacijos. Kvantinės grandinės arba diagramos išvesties apskaičiavimas tiesiogiai iš jos matematinės reprezentacijos, nenaudojant matavimų mėginių.

NumpyModel. *lambeq* modelis, parametrizuotų diagramų išvestis apskaičiuojantis klasikiniu skaitiniu būdu, naudojant NumPy pagrįstus tenzorinius skaičiavimus.

TketModel. *lambeq* modelis, skirtas parametrizuotoms grandinėms vykdyti naudojant *pytket* sąsają ir pasirinktą kvantinio vykdymo aplinką.

SPSA optimizatorius. Stochastinis optimizavimo metodas, kuriame parametro kryptis įvertinama atsitiktiniu būdu perturbuojant parametrų vektorius.

Binary Cross-Entropy (BCE). Dvejtainės klasifikacijos uždaviniuose naudojama nuostolio funkcija, lyginanti tikrąsias etiketes su modelio prognozuotomis tikimybėmis.

Įvadas

Didėjant tekstinės informacijos kiekiui, automatinis tekstų santraukų sudarymas tampa svarbia natūralios kalbos apdorojimo užduotimi. Santraukos leidžia sumažinti dokumentų apimtį ir išlaikyti svarbiausią informaciją, todėl tokie metodai taikomi informacijos paieškoje, dokumentų analizėje, naujienų apdorojime ir kitose srityse. Viena iš santraukų sudarymo krypčių yra ekstraktyvus santraukų sudarymas, kai santrauka sudaroma atrenkant svarbiausius tekstų sakinius jų nekeičiant.

Ekstraktyvų santraukų sudarymą galima formuluoti kaip sakinių klasifikavimo uždavinį: kiekvienam dokumento sakiniui priskiriama etiketė, nurodanti, ar sakinytis turėtų būti įtrauktas į santrauką. Tokia formuluotė leidžia modelio užduotį apibrėžti kaip dvejetainę klasifikaciją, tačiau kartu išlieka svarbus klausimas – kaip įvertinti sakinio svarbą.

Natūralios kalbos apdorojime yra pradėti taikyti kvantinio skaičiavimo principais grindžiami metodai. Kvantinis natūralios kalbos apdorojimas (toliau – QNLP) siekia sujungti kompozicinę kalbos struktūrą su kvantinių grandinių reprezentacijomis. Viena iš šios krypties praktinių realizacijų yra *lambeq* biblioteka, leidžianti sakinius transformuoti į gramatinės diagramas, o vėliau – į parametrizuotas kvantines grandines [KFY⁺21]. Tokia eiga leidžia tirti, ar sakinių gramatinė ir semantinė struktūra gali būti panaudota kvantinio modelio mokymui.

Vis dėlto QNLP taikymas praktinėms natūralios kalbos apdorojimo užduotims vis dar yra ankstyvoje stadijoje. Nėra aišku, kiek tokie modeliai yra tinkami santraukų sudarymo uždaviniui ir kokie atsiranda praktiniai apribojimai.

Šiame darbe tiriamas QNLP modelio taikymas ekstraktyviam santraukų sudarymui. Uždavinys formuluojamas kaip sakinių lygmens dvejetainė klasifikacija: modelis mokomas nustatyti, ar sakinytis turėtų būti įtrauktas į ekstraktyvią santrauką. Tam sudaromas sakinių lygmens duomenų rinkinys, sakiniai transformuojami į *lambeq* naudojamas diagramines reprezentacijas, o vėliau naudojami kvantinio modelio mokymui simuliuojamoje aplinkoje. Tokiu būdu darbe siekiama ne tik apmokyti modelį, bet ir įvertinti, kokios galimybės ir apribojimai išryškėja taikant QNLP reprezentacijas šiam uždaviniui.

Darbo tikslas – įvertinti *lambeq* pagrindu sudaryto QNLP modelio pritaikomumą ekstraktyvaus santraukų sudarymo sakinių klasifikavimo uždaviniui ir nustatyti pagrindinius tokio taikymo praktinius apribojimus.

Šiam tikslui pasiekti keliama šie uždaviniai:

1. sudaryti sakinių lygmens duomenų rinkinį, tinkamą ekstraktyvaus santraukų sudarymo klasifikavimo uždaviniui;
2. parengti sakinių transformavimo į QNLP modelio mokymui tinkamas kvantinių grandinių reprezentacijas eigą;
3. pritaikyti *lambeq* pagrindu sudarytą modelį sakinių klasifikavimo uždaviniui;
4. atlikti modelio mokymo eksperimentus;

5. įvertinti gautus rezultatus ir nustatyti pagrindinius metodo privalumus, trūkumus ir apribojimus.

Darbo rezultatas – eksperimentais įvertinta QNLP modelio taikymo ekstraktyvaus santraukų sudarymo sakinių klasifikavimo uždaviniui eiga. Darbe siekiama parodyti, ar toks metodas gali būti pritaikytas praktiniam sakinių atrankos uždaviniui, ir kokie techniniai bei metodiniai apribojimai išryškėja.

1. DisCoCat modelis ir semantinė vektorinė kompozicija

DisCoCat modelis (angl. Distributional Compositional Categorical) yra kompozicinės semantikos formalizmas, jungiantis paskirstytas žodžių reikšmių reprezentacijas su gramatine sakinio struktūra [CSC10]. Pagrindinė šio modelio idėja yra ta, kad sakinio reikšmė nėra gaunama vien iš atskirų žodžių reikšmių sumos; ji priklauso ir nuo to, kaip žodžiai sintaksiškai susijungia sakinyje.

Klasikiniame *DisCoCat* modelyje žodžiai gali būti vaizduojami vektoriais arba aukštesnės eilės tenzoriais, o gramatinė sakinio struktūra nurodo, kokios tenzorinės kontrakcijos turi būti atliktos norint gauti viso sakinio semantinę reprezentaciją. Pavyzdžiui, daiktavardžiai gali būti reprezentuojami vektoriais, o tranzityvūs veiksmažodžiai – aukštesnės eilės tenzoriais, kurie sujungia subjekto ir objekto reprezentacijas į sakinio reprezentaciją.

Šiame darbe *DisCoCat* principas taikomas kvantinio natūralios kalbos apdorojimo kontekste. Sakiniai pirmiausia analizuojami naudojant *DepCCGParser* [YNM17], kuris sakiniams priskiria kombinatorinės kategorinės gramatikos struktūras. Vėliau naudojant *lambeq* [KFY⁺21] šios struktūros transformuojamos į pregrouptipo diagramas, kurios, taikant pasirinktą *ansatz*, paverčiamos parametrizuotomis kvantinėmis grandinėmis.

Kategorijų tenzoriai:

- Paprastos kategorijos, pvz. N ar NP , atitinka vektorius v_N ar v_{NP} .
- Funkcinės kategorijos (A/B) reprezentuojamos matricomis arba aukštesnės eilės tenzoriais, pavyzdžiui, $T_{(S \setminus NP)/NP} \in \mathbb{R}^{d \times d \times d}$, kuris „įjungia“ dešinės kategorijos ir kairės kategorijos įterpinius (angl. embeddings), kad susidarytų rezultato erdvė $\mathbb{R}^d$. Tenzorinė sandauga žymima simboliu $\otimes$, tačiau galutinė sakinio reprezentacija gaunama ne vien sudarant sandaugą, bet atliekant tenzorines kontrakcijas, t. y. sutraukiant tarpusavyje susijusias gramatines dimensijas, kai kelių vektorių ar tenzorių sandauga paverčiama mažesnės eilės tenzoriumi arba vektoriumi.

Pavyzdžiui, sakinyje „Gitanas glosto šuniuką“ subjektas ir objektas gali būti vaizduojami kaip daiktavardinių frazių reprezentacijos, o tranzityvus veiksmažodis – kaip aukštesnės eilės tenzorius. Gramatinė struktūra nurodo, kaip šios reprezentacijos jungiamos, kad būtų gauta sakinio reprezentacija:

$$v_{\text{Gitanas}} \otimes T_{\text{glosto}} \otimes v_{\text{šuniuką}} \longrightarrow v_S.$$

Indeksinė tenzorinės kontrakcijos išraiška:

$$(v_S)_i = \sum_{j,k} T_{ijk}^{\text{veiksm}} (v_{\text{subj}})_j (v_{\text{obj}})_k.$$

Čia v_{subj} žymi subjekto reprezentaciją, v_{obj} – objekto reprezentaciją, o T^{veiksm} – tranzityvaus veiksmažodžio tenzorių. Indeksai j ir k yra sutraukiami, todėl rezultatas yra sakinio reprezentacijos vektorius v_S .

1.1. Kombinatorinė kategorinė gramatika

Kombinatorinė kategorinė gramatika (angl. Combinatory Categorical Grammar) [Ste00] (toliau – CCG), yra gramatikos formalizmas, kuriame kiekvienas žodis ar frazė pažymima tam tikros CCG kategorijos išraiška.

Pagrindinės kategorijos yra:

- *S* – sakinys (angl. sentence);
- *N* – daiktavardis (angl. noun);
- *NP* – daiktavardžio frazė (angl. noun phrase);
- *PP* – prielinksnio frazė (angl. prepositional phrase);

Mažiau fundamentalios:

- *ADJ* – būdvardis (angl. adjective);
- *ADV* – prieveiksmis (angl. adverb);
- *CONJ* – jungtukas (angl. conjunction);
- *PUNC* – skyrybos ženklas (angl. punctuation).

Realiuose CCG parserių rezultatuose kategorijos gali būti gerokai sudėtingesnės ir turėti papildomų požymių, tačiau pateikiamos supaprastintos kategorijos, reikalingos pagrindiniam *DisCoCat* principui paaiškinti.

Šiame tyrime CCG analizė naudojama kaip praktinis sintaksinės analizės formalizmas, leidžiantis gauti sakinio struktūros reprezentaciją diagrama, kuri vėliau *lambeq* aplinkoje transformuojama į *DisCoCat* tipo diagramą.

1.2. DisCoCat funkcinės kategorijos

DisCoCat modelis sujungia CCG su vektorinėmis reprezentacijomis: kiekvienai gramatinei kategorijai priskiriama atitinkama vektorinė arba Hilberto erdvė, o žodžių reikšmės vaizduojamos šių erdvių vektoriais arba tenzoriais.

Funkcinės (kompleksinės) kategorijos aprašo funkcijas, paimančias vieną arba kelis argumentus ir grąžinančias rezultatą:

$$Y/X \quad X \Rightarrow Y \quad (1)$$

čia X, Y yra kintamieji - vietoje jų yra įstatomos *DisCoCat* kategorijos S, N, NP ir kt. (žr. skyrių 1.1).

Priekinio taikymo taisyklė (angl. Forward application), pavaizduota 1 lygtyje, kur prie vienargumentinio veiksmažodžio, kuris turi X iš dešinės (Y/X), paima X ir grąžina Y .

$$X \quad Y/X \Rightarrow Y \quad (2)$$

Atgalinio taikymo taisyklė (angl. Backwards application), pavaizduota 2 lygtyje – vienargumentis veiksmažodis turi X iš kairės ($Y \backslash X$), jam padavus X iš kairės grąžinama Y .

Toliau aptarsime, kaip CCG kategorijos iš „atominio“ lygmens (S, NP, N ir kt.) pakeičiamos į funkcines kategorijas, kurios leidžia užrašyti žodžių tarpusavio ryšius griežtomis kombinatorinėmis taisyklėmis.

- **Intransityvus veiksmažodis** (vienargumentis): priima vieną „subjektą“ NP ir grąžina pilną sakinį S.

$$S \backslash NP \quad (3)$$

Pavyzdys: „Gitanas miega.“

- „miega“: $S \backslash NP$
- „Gitanas“: NP
- naudojant galinį taikymą:

$$NP \quad (S \backslash NP) \Rightarrow S$$

Jeigu sakinyje būtų sukeista žodžių tvarka į „Miega Gitanas“, tuomet:

- „Miega“: S/NP
- „Gitanas“: NP
- naudojant Priekinį taikymą:

$$(S/NP) \quad NP \Rightarrow S$$

- **Tranzityvus veiksmažodis**: priima objektą NP dešinėje, paskui subjektą NP kairėje, ir grąžina S.

$$(S \backslash NP)/NP \quad (4)$$

Pavyzdys: „Gitanas glosto šuniuką.“

- „glost“: $(S \backslash NP)/NP$
- „šuniuką“: NP
- naudojant Priekinį taikymą:

$$(S \backslash NP)/NP \quad NP \Rightarrow S \backslash NP$$

- „Gitanas“: NP
- naudojant Galinį taikymą:

$$NP \quad (S \backslash NP) \Rightarrow S$$

- **Prieveiksmių kategorija:** modifikuoja veiksmą (tranzityvų ar intransityvų veiksmažodį), priimdama ir grąžindama tą patį veiksmažodžio tipą.

$$(S \backslash NP) / (S \backslash NP) \quad (5)$$

Pavyzdys: sakinyje „Gitanas smagiai glosto šuniuką.“

- „smagiai“: $(S \backslash NP) / (S \backslash NP)$
- „glosto šuniuką“: $S \backslash NP$
- naudojant Priekinį taikymą:

$$(S \backslash NP) / (S \backslash NP) \quad (S \backslash NP) \Rightarrow S \backslash NP$$

- **Jungtuko kategorija:** sujungia du tos pačios kategorijos vienetus (pvz. NP arba S) į vieną visumą.

$$(X \backslash X) / X \quad (6)$$

Čia X gali būti bet kuri kategorija (pvz. NP arba S). Pavyzdys su NP : „Gitanas ir Gintaras glosto šuniuką.“

- „ir“: $(NP \backslash NP) / NP$
- „Gintaras“: NP
- naudojant Priekinį taikymą:

$$(NP \backslash NP) / NP \quad NP \Rightarrow NP \backslash NP$$

- „Gitanas“: NP
- naudojant Galinį taikymą:

$$NP \quad (NP \backslash NP) \Rightarrow NP$$

- Toliau gaunamą NP jungiam su veiksmažodžiu tą pačią Priekinio taikymo ar kitą CCG taisyklę.

Nors atrodo, jog funkcija „ $S \backslash NP$ “ atitinka veiksmažodžius, tačiau funkcinėmis kategorijomis veiksmažodžių vadinti negalima. „ $S \backslash NP$ “ yra funkcinė kategorija, kurią gauna tokie žodžiai kaip intransityvūs veiksmažodžiai („ateina“, „miega“, „krenta“). Ji yra gramatinis tipas, nurodantis,

kokio argumento reikia tam tikram žodžiui ar frazei ir kokį rezultatą ši kombinacija grąžina. Taigi, CCG funkcinės kategorijos yra gramatiniai tipai, o ne patys žodžiai; kiekvienam žodžiui ar frazei priskiriama atitinkama kategorija, pagal kurią vykdomi funkcijų taikymo principai ir sudaromas galutinis sakiny S .

Tokiu būdu CCG išreiškia visą sakinio struktūrą griežtomis kombinatorinėmis taisyklėmis, o *DisCoCat* vektorinė semantika sujungia kiekvieną kategoriją su vektoriais ir tenzoriais, kad būtų galima atlikti semantines kontrakcijas ir gauti sakinio semantinę reprezentaciją.

2. Duomenų rinkinio sudarymas

2.1. Duomenų rinkinio pasirinkimo kriterijai

Ekstraktyvus santraukų sudarymas formuluojamas kaip sakinių klasifikavimo uždavinys. Kiekvienam dokumento sakiniui priskiriama dvejetainė etiketė, nurodanti, ar sakinytis turėtų būti įtrauktas į ekstraktyvią santrauką. Tokia formuluo­­tė yra dažnai taikoma ekstraktyvaus santraukų sudarymo modeliuose, kuriuose dokumentas suskaidomas į sakinius, o modelis kiekvienam sakiniui prognozuoja jo svarbą santraukai.

Kadangi Šiame tyrime naudojamas kvantinio natūralios kalbos apdorojimo modelis, duomenų rinkiniui keliama papildomi praktiniai apribojimai. Kiekvienas sakinytis turi būti sintaksiškai analizuojamas, paverčiamas į diagramos reprezentaciją ir vėliau transformuojamas į parametrizuotą kvantinę grandinę, žr. skyrių 3.4. Todėl labai ilgi, turintys sudėtingą sintaksę ar punktuaciją arba stipriai nesubalansuoti duomenys gali reikšmingai apsunkinti modelio mokymą.

Atsižvelgiant į tai, duomenų rinkinytis turėjo atitikti šiuos kriterijus:

- tekstai turi būti suskaidomi į atskirus sakinius;
- kiekvienam sakiniui turi būti priskirta dvejetainė etiketė;
- teigiamų ir neigiamų etikečių santykis neturi būti pernelyg nesubalansuotas;
- tekstai turi būti pakankamai trumpi ir sintaksiškai nesudėtingi, kad būtų tinkami transformavimui į kvantines grandines;
- pridėtinis privalumas - sakiniai nėra aukšto punktuacinio sudėtingumo;
- duomenų rinkinytis turi būti susijęs su santraukų sudarymo uždaviniu.

2.2. Pirminis duomenų rinkinio pasirinkimas: CNN/DailyMail ir PreSumm

Pradiniame darbo etape buvo nagrinėtas *CNN/DailyMail* duomenų rinkinytis [NZG⁺16], paruoštas naudojant *PreSumm/BERTSum* [Liu19] tipo apdorojimo eigą. *CNN/DailyMail* yra vienas dažniausiai naudojamų naujienų santraukų sudarymo duomenų rinkinių, o *BERTSum* [LL19] tipo modeliuose ekstraktyvus santraukų sudarymas formuluojamas kaip sakinių klasifikavimo uždavinys, kuriame kiekvienam dokumento sakiniui priskiriama etiketė, nurodanti, ar sakinytis priklauso santraukai.

Šis duomenų rinkinytis iš pirmo žvilgsnio atitiko svarbų šio darbo kriterijų: dokumentai buvo suskaidyti į sakinius, o sakiniams buvo priskirtos dvejetainės etiketės. Vis dėlto atlikus duomenų analizę pastebėta, kad teigiamų etikečių dalis yra labai maža. Vidutiniškai viename dokumente buvo apie 35 sakiniai, iš kurių tik apie 2–3 sakiniai buvo pažymėti kaip įtrauktini į ekstraktyvią santrauką. Tai sudarė maždaug 7% teigiamų etikečių.

Toks etikečių pasiskirstymas yra problemiškas naudojamam modeliui. Esant stipriai klasių disproporcijai, modelis gali pasiekti santykinai aukštą tikslumą prognozuodamas daugumą sakinių kaip neįtrauktinus į santrauką, tačiau toks rezultatas neatspindėtų realaus santraukų sudarymo gebėjimo. Be to, kvantinio modelio mokymas yra skaičiavimo požiūriu brangus, todėl labai nesubalansuoti duomenys mažina mokymo efektyvumą ir apsunkina teigiamų pavyzdžių atpažinimą.

Dėl stipraus klasių disbalanso *CNN/DailyMail* pagrindu sudarytas *PreSumm* tipo duomenų rinkinys nebuvo optimalus kaip pagrindinis šio darbo mokymo duomenų šaltinis.

Vidutinis sakinių skaičius rinkinyje	35.89
Vidutinis teigiamų etikečių skaičius rinkinyje	2.58
Teigiamų etikečių dalis	7.19%

1 lentelė. *CNN/DailyMail* pagrindu sudaryto duomenų rinkinio etikečių pasiskirstymas

2.3. WikiHow duomenų rinkinys

Atsižvelgiant į *CNN/DailyMail* pagrindu sudaryto duomenų rinkinio klasių disbalansą, darbe buvo pasirinktas *WikiHow* duomenų rinkinys [KW18]. *WikiHow* yra didelio masto santraukų sudarymo duomenų rinkinys, sudarytas iš instrukcinio pobūdžio straipsnių ir jų santraukų. Skirtingai nei naujienų duomenų rinkiniai, *WikiHow* tekstai apima įvairias temas ir nėra apriboti vien naujienų rašymo stiliumi.

Šis duomenų rinkinys pasirinktas dėl kelių priežasčių. Pirma, *WikiHow* straipsniai dažnai turi aiškesnę struktūrą nei naujienų straipsniai: juose mažiau citatų, žurnalistinio konteksto, autorių paminėjimų ar kitų dalių, kurios nėra tiesiogiai susijusios su pagrindiniu teksto turiniu. Antra, instrukcinio pobūdžio tekstai dažnai yra sudaryti iš konkretesnių ir trumpesnių informacinių vienetų, todėl jie yra patogesni sakinių lygmens klasifikavimo uždaviniui. Trečia, trumpesni ir aiškesni sakiniai yra tinkamesni kvantinio natūralios kalbos apdorojimo eigai, kadangi sudėtingi sakiniai gali būti transformuojami į stipriai dideles kvantines grandines.

Darbo eksperimentuose buvo naudota *WikiHowSep* duomenų rinkinio versija, kurioje nagrinėjami ne pilni straipsniai, o atskiros straipsnių pastraipos. Tokiu atveju duomenys sudaryti iš konkrečių minčių ar temos fragmentų. Be to, sumažina įvesties teksto ilgį ir leidžia dirbti su konkretesniais semantiniais vienetais. Tai yra svarbu, nes kiekvienas sakinytis vėliau analizuojamas naudojant *DepCCGParser*, transformuojamas į diagramą ir paverčiamas kvantine grandine. Plačiau apie duomenų transformavimą į kvantines grandines 3 skyriuje.

Nors *WikiHow* duomenų rinkinys yra skirtas santraukų sudarymo uždaviniams, jis tiesiogiai nepateikia šio darbo tikslams pasiekti reikalingų dvejetainių, sakinio lygmens, etikečių. Todėl sakinių etiketės buvo sudarytos papildomu žingsniu, naudojant iš anksto apmokytą ekstraktyvaus santraukų sudarymo modelį.

2.4. Sakinių etikečių sudarymas naudojant TransformerSum

Kadangi *WikiHow* duomenų rinkinys tiesiogiai nepateikia kiekvieno sakinio dvejetainės etiketės, reikalingos šio darbo formuluojamam sakinių klasifikavimo uždaviniui, buvo atliktas papildomas etikečių sudarymo etapas. Sakinių svarbos įverčiams apskaičiuoti naudotas *TransformerSum* modelis *distilroberta-base*, apmokytas *WikiHow* duomenų rinkiniui. Naudotas *HuggingFace* saugykloje pateiktas $\text{epoch}=3$.ckpt kontrolinis taškas [HHo24].

Naudojant iš anksto apmokytą ekstraktyvaus santraukų sudarymo modelį, kiekvienam pastraipos sakiniui buvo apskaičiuotas svarbos įvertinimas. Pagal šiuos įverčius sakiniai buvo suskirstyti į dvi klases:

- teigiama klasė – sakinyi laikomas tinkamu ekstraktyviai santraukai;
- neigiama klasė – sakinyi nelaikomas tinkamu ekstraktyviai santraukai.

2.5. Mokymo ir validavimo bei testavimo rinkiniai

Modelio mokymo metu klasių disbalansas gali apsunkinti teigiamos klasės atpažinimą, nes modelis gali būti linkęs dažniau prognozuoti dominuojančią neigiamą klasę. Ši problema ypač aktuali šiame darbe, kadangi kvantinio modelio mokymas yra skaičiavimo požiūriu brangus.

Kita vertus, ekstraktyvaus santraukų sudarymo uždavinyje į santrauką įprastai patenka tik nedidelė dalis dokumento sakinių. Todėl visiškai subalansuotas teigiamų ir neigiamų etikečių santykis nėra realistiškas vertinimo scenarijus. Atsižvelgiant į tai, buvo pasirinktos dvi sakinių atrankos strategijos: *top-ratio* metodas mokymo rinkiniui sudaryti ir *z-įverčio* metodas validavimo bei testavimo rinkiniams sudaryti.

2.5.1. Top-ratio

Kadangi kvantinio modelio mokymas su stipriai nesubalansuotomis klasėmis yra problemiškas, mokymo rinkiniui buvo sudarytas labiau subalansuotas etikečių pasiskirstymas, naudojant *top-ratio* metodą. Šiuo metodu teigiamai klasei priskiriama nustatyta dalis sakinių, gavusių aukščiausius svarbos įvertinimus.

Jeigu pastraipą sudaro n sakinių, o pasirinktas santykis yra r , teigiamai klasei priskiriamų sakinių skaičius apskaičiuojamas taip:

$$k = \lceil r \cdot n \rceil \quad (7)$$

kur k yra teigiamai klasei priskiriamų sakinių skaičius. Naudojant *top-ratio* reikšmę 0,4, gauta apytikslė teigiamų ir neigiamų etikečių proporcija buvo 47:53.

2.5.2. z-įvertis

Skirtingų pastraipų sakinių svarbos įverčiai gali būti nevienodai pasiskirstę, todėl etiketės buvo sudaromos normalizuojant sakinių įverčius pastraipos lygmeniu. Tam buvo naudojamas *z-įverčio*

principas:

$$z_i = \frac{s_i - \mu}{\sigma}, \quad (8)$$

kur s_i yra i -ojo sakinio svarbos įvertis, gautas naudojant *TransformerSum* ekstraktyvaus santraukų sudarymo modelį, μ – visų pastraipos sakinių įverčių vidurkis, o σ – standartinis nuokrypis. Sakinys buvo pažymimas kaip teigiamas, jeigu jo įvertis tenkino sąlygą:

$$s_i \geq \mu + \alpha\sigma, \quad (9)$$

kur šiame darbe naudota $\alpha = 0.5$.

Papildomai buvo taikomi apribojimai, užtikrinantys, kad kiekviena pastraipa turėtų bent vieną teigiamą sakinį, bet ne daugiau kaip penkis teigiamus sakinius.

z-įverčio metodas sudarė maždaug 24:76 teigiamų ir neigiamų etikečių proporciją, o tai labiau atitinka ekstraktyvaus santraukų sudarymo prielaidą, kad į santrauką patenka nedidelė dalis dokumento sakinių. Būtent dėl to z-įverčio metodas buvo taikytas validavimo ir testavimo rinkiniams sudaryti.

2.6. Gautas duomenų rinkinys

Galutinis naudotas duomenų rinkinys nebuvo tiesiogiai paimtas iš originalaus *WikiHow* formato. Jis buvo sudarytas pritaikius papildomą sakinių lygmens etikečių generavimo procedūrą. Kiekvienai pastraipai pirmiausia buvo apskaičiuoti sakinių svarbos įverčiai naudojant iš anksto apmokytą *TransformerSum* ekstraktyvaus santraukų sudarymo modelį, o vėliau pagal pasirinktą atrankos metodą sakiniams priskirtos dvejetainės etiketės.

Prieš etikečių sudarymą buvo pašalinti tekstai, turintys mažiau nei 7 sakinius. Šis apribojimas taikytas siekiant užtikrinti, kad kiekvienoje pastraipoje būtų pakankamas sakinių kiekis prasmingai ekstraktyviai atrankai atlikti.

Svarbu pažymėti, kad šiame darbe naudotos sakinių etiketės nėra žmogaus sudarytos anotacijos. Jos buvo sugeneruotos naudojant iš anksto apmokytą klasikinį ekstraktyvaus santraukų sudarymo modelį. Tokiu atveju *TransformerSum* modelis atlieka mokytojo modelio funkciją, o sudarytas duomenų rinkinys gali būti laikomas silpnos priežiūros pagrindu suformuotu sakinių klasifikavimo rinkiniu. Dėl šios priežasties kvantinis modelis nėra mokomas tiesiogiai pagal žmogaus anotacijas; jis mokomas atkartoti sakinių atrankos struktūrą, kurią sugeneravo klasikinis mokytojo modelis.

Mokymo ir vertinimo rinkinių etiketės buvo sudarytos skirtingais kriterijais. Mokymo rinkiniui naudotas *top-ratio* metodas, siekiant sumažinti klasių disbalansą ir užtikrinti pakankamą teigiamų pavyzdžių kiekį mokymo metu. Validavimo ir testavimo rinkiniams naudotas z-įverčio metodas, leidžiantis išlaikyti konservatyvesnį ir realistiškesnį teigiamų sakinių kiekį. Todėl vertinimo rezultatai šiame tyrime interpretuojami ne tik kaip klasifikavimo tikslumo matas, bet ir kaip modelio gebėjimas generalizuoti į griežtesnį sakinių atrankos kriterijų.

3. Duomenų transformavimo veiksmai

Prieš pateikiant sakinius kvantiniam modeliui, tekstiniai duomenys buvo transformuojami ke-
liais etapais. Šio proceso tikslas – iš pradinio sakinio teksto gauti tokią reprezentaciją, kuri galėtų
būti panaudota *lambeq* aplinkoje parametrizuotoms kvantinėms grandinėms sudaryti.

Duomenų transformavimo eiga sudaryta iš šių etapų:

1. sakinių supaprastinimas ir specialiųjų simbolių pašalinimas, aprašomas 3.1 poskyryje;
2. sakinių transformavimas į gramatinės diagramas, aprašomas 3.2 poskyryje;
3. diagramų normalizavimas, aprašomas 3.3 poskyryje;
4. normalizuotų diagramų transformavimas į parametrizuotas kvantines grandines, aprašomas
3.4 poskyryje;
5. gautų kvantinių grandinių filtravimas pagal techninius apribojimus, aprašomas 3.5 poskyryje.

3.1. Sakinių supaprastinimas

Prieš sakinius perduodant gramatiniam analizatoriui, buvo atliekamas jų supaprastinimas. Šio
žingsnio tikslas – sumažinti sakinių sintaksinį sudėtingumą ir pašalinti tokias sakinio dalis, kurios
dažnai padidina gramatinės analizės bei vėliau sudaromos kvantinės grandinės sudėtingumą, tačiau
nėra būtinos pagrindinei sakinio minčiai išlaikyti.

Sakinių supaprastinimui pasitelkta *spaCy* `en_core_web_trf` modelis [HMT⁺20]. Naudojant
priklausomybių analizę, iš sakinių buvo šalinamos tam tikros sintaksinės konstrukcijos:

- `appos` – priedėliai;
- `acl` – daiktavardį modifikuojantys šalutiniai dėmenys;
- `advcl` – prieveiksminiai šalutiniai dėmenys;
- `relcl` – santykiniai šalutiniai dėmenys.

Atrinktos būtent šios konstrukcijos dėl to, kad jos dažnai išplečia sakinį papildoma informacija
ir padidina sintaksinės struktūros sudėtingumą.

Kadangi kiekvienas sakiny s vėliau yra transformuojamas į diagramą ir kvantinę grandinę, per
ilgos arba sudėtingos konstrukcijos gali reikalauti didesnio kubitų ir vartų skaičiaus arba didesnio
grandinės gylio. Toks sakinių pertvarkymo būdas ne tik sumažina sintaksinį sudėtingumą, bet ir
išlaiko pagrindinę sakinio mintį, ir vėliau gali būti sudaromos mažesnės kvantinės grandinės.

Sintaksinių konstrukcijų pašalinimo pavyzdžiai pateikti 2 lentelėje. Pavyzdžiai yra anglų kalba,
nes darbas buvo atliekamas naudojant anglų kalbos tekstus.


Pradinis sakiny	Konstrukcija	Sutrumpintas sakiny
<i>My friend, a well-known scientist, published a paper.</i>	appos	<i>My friend published a paper.</i>
<i>The book that I read yesterday was fascinating.</i>	relcl	<i>The book was fascinating.</i>
<i>The student selected for the scholarship gave a speech.</i>	acl	<i>The student gave a speech</i>
<i>The president, speaking in Paris, announced sanctions while addressing the media.</i>	advcl	<i>The president announced sanctions.</i>

2 lentelė. Sakinių supaprastinimo naudojant *spaCy* priklausomybių analizę pavyzdžiai

Po sintaksinio supaprastinimo sakiniams papildomai taikytas simbolių valymo žingsnis. Jo metu pašalinti pertekliniai skyrybos, citavimo ir kiti specialieji simboliai, kurie nėra reikalingi gramatinei analizei arba gali ją apsunkinti.

Svarbu pažymėti, kad sakinių supaprastinimas yra praktinis kompromisas: jis sumažina transformavimo į diagramas sudėtingumą, tačiau kartu gali pašalinti dalį papildomos semantinės informacijos. Todėl šis žingsnis buvo taikomas siekiant išlaikyti pagrindinę sakinio struktūrą, bet sumažinti techninius apribojimus, atsirandančius vėlesniuose kvantinių grandinių sudarymo etapuose.

3.2. Sakinių transformavimas į diagramas




1 pav. Sakinio transformavimo į gramatinę diagramą pavyzdys.

Supaprastinti sakiniai buvo perduodami *lambeq* bibliotekos *DepCCGParser* analizatoriui. *DepCCGParser* sakiniams priskiria gramatinę struktūrą, kuri *lambeq* aplinkoje reprezentuojama kaip diagramos objektas.

Po šio proceso kiekvienas sėkmingai išanalizuotas sakiny tampa *Diagram* tipo objektu. Tokia diagrama aprašo sakinio kompozicinę struktūrą: žodžiai vaizduojami kaip dėžutės, o tarp jų esančios jungtys nurodo, kaip gramatinės kategorijos susijungia į bendrą sakinio reprezentaciją.

Pav. 1 pateiktas pavyzdys, kuriame sakiny „Gitanas nusprendė pasivaikšėti parke ir paglostyti šuniuką“ pavaizduotas kaip gramatinė diagrama. Viršutinėje diagramos dalyje pateikiami sakinio žodžiai, o iš jų išeinančios vielos žymi gramatinius tipus. Pavyzdžiui, tipas *n* atitinka daiktavardinę kategoriją, o *n.l* ir *n.r* žymi atitinkamai kairįjį ir dešinįjį šios kategorijos tipus.



2 pav. Perraišytos ir normalizuotos gramatinės diagramos pavyzdys.

Žymėjimai .l ir .r diagramose naudojami gramatinių redukcijų kryptį nusakyti. Tokios jungtys leidžia iš atskirų žodžių gramatinių kategorijų sudaryti bendrą sakinio struktūrą.

Kiekvienas sėkmingai išanalizuotas sakinyje įgauna diagramos reprezentaciją, kuri gali būti naudojama tolimesniam transformavimui į parametrizuotą kvantinę grandinę.

3.3. Diagramų normalizavimas ir perrašymas

Pradinės gramatinės diagramos, gautos naudojant *DepCCGParser*, gali būti labai sudėtingos – diagramose gali atsirasti papildomų funkcinių, kurios didina vėliau sudaromos kvantinės grandinės dydį. *Lambeq* suteikia diagramų perrašymo ir normalizavimo įrankius, kurie supaprastina diagramas.

Šio etapo tikslas – sumažinti diagramų sudėtingumą, pašalinti dalį perteklinių gramatinių konstrukcijų ir suvienodinti diagramų išvesties tipą. Tai svarbu todėl, kad *lambeq* aplinkoje kvantinė grandinė sudaroma pagal diagramos struktūrą: kuo sudėtingesnė diagrama, tuo daugiau gali reikėti kubitų, kvantinių vartų arba didesnio grandinės gylio. Todėl diagramų normalizavimas šiame darbe buvo naudojamas kaip praktinis būdas sumažinti kvantinių grandinių sudėtingumą prieš jų generavimą.

Rewriter(). Pirmiausia diagramoms taikytas *lambeq* bibliotekos *Rewriter* įrankis. Jam buvo perduotas pasirinktų perrašymo taisyklių sąrašas:

```
['determiner', 'coordination', 'prepositional_phrase']
```

Šios taisyklės naudojamos tam tikroms gramatinėms konstrukcijoms supaprastinti arba pašalinti. Taisyklė *determiner* skirta determinatoriams, pavyzdžiui, anglų kalbos artikeliams *the* arba *a*, tvarkyti. Taisyklė *coordination* taikoma koordinacijos konstrukcijoms, pavyzdžiui, jungtuku sujungtoms frazėms. Taisyklė *prepositional_phrase* susijusi su prielinksnių frazių supaprastinimu.

Panašiai kaip ir sakinių supaprastinime, žr. skyrių 3.1, šis žingsnis gali sumažinti sakinių semantinę informaciją. Tačiau stipresnis poveikis yra sumažintas diagramos gramatinių komponentų kiekis ir pašalintos konstrukcijos, kurios gali reikšmingai padidinti kvantinės grandinės sudėtingumą.

RemoveCupsRewriter(). Po bendrojo perrašymo diagramai taikytas **RemoveCupsRewriter**. Šis įrankis pašalina vadinamąsias *cup* tipo jungtis, kurios *pregroup* gramatikos diagramose atitinka gramatinės redukcijas. Tokios jungtys parodo, kaip tarpusavyje panaikinami arba sujungiami adjungtiniai gramatiniai tipai.

Kvantinių grandinių sudarymo požiūriu *cup* jungtys gali padidinti grandinės sudėtingumą, nes jos reikalauja papildomų struktūrinių ryšių tarp diagramos dalių. Pašalinus šias jungtis, dalis gramatinių sutraukimų atliekama dar prieš kvantinės grandinės sudarymą.

Šis žingsnis yra praktinis kompromisas: pašalinus *cup* jungtis, sumažinamas grandinių dydis ir palengvinamas jų simuliacijavimas, tačiau dalis kompozicinės struktūros nebėra tiesiogiai reprezentuojama pačioje kvantinėje grandinėje.

.normal_form(). Po **RemoveCupsRewriter** taikymo diagrama buvo pertvarkoma į normaliąją formą naudojant metodą **normal_form()**. Šis metodas pertvarko diagramą į standartizuotą formą pagal diagramų perrašymo taisykles. Praktiniu požiūriu tai leidžia sumažinti lokalius struktūrinius skirtumus tarp diagramų, kurie gali atsirasti po gramatinės analizės arba po ankstesnių perrašymo žingsnių. Normalizavimo žingsnis užtikrina, kad vėlesni transformavimo žingsniai būtų taikomi nuoseklesnei diagramos struktūrai.

UnifyCodomainRewriter(). Toliau taikytas **UnifyCodomainRewriter**, kurio išvesties tipas nustatytas į sakiny, arba kitaip – *lambeq* tipas **AtomicType.SENTENCE**:

```
UnifyCodomainRewriter(output_type=AtomicType.SENTENCE)
```

Šis žingsnis suvienodina diagramų „kodomeną“, t.y. jų išvesties tipą. Kadangi kiekviena diagrama reprezentuoja sakinį, galutinė diagramos išvestis turi atitikti sakinio tipą. Tai ypač svarbu kadangi pagrindinė užduotis yra sakinių klasifikavimas, ir kvantinis modelis turi gaminti sakinio išvestis.

.normal_form(). Galiausiai po kodomeno suvienodinimo dar kartą taikytas **normal_form()** metodas tam, kad po **UnifyCodomainRewriter** atliktų pakeitimų diagrama vėl būtų struktūriškai sutvarkyta į standartizuotą formą.

Šių žingsnių rezultatas yra supaprastinta ir suvienodinta gramatinė diagrama, paruošta transformavimui į parametrizuotą kvantinę grandinę. Sutvarkytos diagramos pavyzdys pateiktas pav. 2.

3.4. Kvantinių grandinių generavimas

Po diagramų normalizavimo ir perrašymo kiekviena sėkmingai apdorota diagrama turi suvienodintą išvesties tipą ir supaprastintą struktūrą, todėl ji gali būti transformuojama į parametrizuotą kvantinę grandinę. Šis etapas yra būtinas, nes gramatinė diagrama pati savaime dar nėra vykdoma

kvantinė programa. Tam, kad ji galėtų būti naudojama kvantiniame modelyje, jos struktūra turi būti užkoduota kvantinių vartų seka.

Diagramų transformavimui į kvantines grandines naudotas *lambeq* bibliotekos *IQPAnsatz* (toliau – *ansatz*). *Ansatz* apibrėžia taisykles, pagal kurias gramatinės diagramos tipai ir žodžių dėžutės paverčiamos parametrizuotais kvantiniais vartais. Kitaip tariant, *ansatz* nusako, kaip iš diagraminės sakinio reprezentacijos sudaroma kvantinė grandinė su mokomais parametrais.

Sudarant *ansatz* grandines priskiriamas kubitų paskirstymo žemėlapis, kuriame nurodoma, kiek kubitų priskirti specifinės sakinio dalims.

3.4.1. Kvantinių bitų paskirstymo žemėlapis

Prieš generuojant kvantines grandines apibrėžiamas kubitų paskirstymo žemėlapis, nusakantis, kiek kubitų skiriama kiekvienam *lambeq* naudojamam atominiam tipui.

```
ansatz = IQPAnsatz(
    {
        AtomicType.SENTENCE: 1,
        AtomicType.NOUN: 1,
    },
    n_layers=1,
    n_single_qubit_params=3
)
```

Sakinio tipui (*AtomicType.SENTENCE*) ir daiktavardžio tipui (*AtomicType.NOUN*) buvo priskirta po vieną kubitą. Priskirtas kubitų skaičius lemia, kiek kvantinės vietos skiriama informacijai laikyti atitinkamiems gramatiniais tipams, ir nurodo, kokio dydžio kvantinė erdvė priskiriama konkrečiam gramatiniam tipui. Taigi, didesnis kubitų kiekis leidžia naudoti didesnę reprezentacinę erdvę, tačiau kartu didina ir sudaromos kvantinės grandinės sudėtingumą.


Jeigu kuriam nors atominiam tipui priskiriama 0 kubitų, toks tipas kvantinėje grandinėje negauna atskiros kvantinės reprezentacijos ir neprisideda prie bendro kubitų skaičiaus. Tuo tarpu jei tipas *ansatz* konfigūracijoje apskritai nėra nurodytas, tačiau pasitaiko diagramoje, grandinės generavimas gali nepavykti, nes *ansatz* neturi apibrėžtos taisyklės, kaip tokį tipą užkoduoti.

Parametras *n_layers=1* nurodo, kad *ansatz* struktūroje naudojamas vienas parametrizuotų kvantinių vartų sluoksnis. Parametras *n_single_qubit_params=3* reiškia, kad vieno kubito operacijoms naudojami trys parametrai. Šie parametrai vėliau tampa modelio mokymo metu optimizuojamais dydžiais.

3.4.2. Parametrizuotos kvantinės grandinės generavimas

Kiekvienai supaprastintai diagramai iškviečiame

$$\text{ansatz_grandinė} = \text{IQPAnsatz}(\text{žemėlapis})(\text{diagrama}), \quad (10)$$



3 pav. *Ansatz* sugeneruotos kvantinės grandinės pavyzdys.

kur sugeneruojamas parametrizuotas kvantinės grandinės objektas, diagrama žymi normalizuotą diagramą, o žemėlapis – kubitų paskirstymo žemėlapi (žr. poskyrį 3.4.1). Kiekviena sugeneruota kvantinė grandinė atitinka vieną sakinį ir išlaiko jo gramatinės diagramos struktūrą parametrizuotų kvantinių vartų pavidalu. Šios grandinės vėliau naudojamos kvantinio modelio mokymo etape.

Šiame etape sudaromos parametrizuotos kvantinės grandinės, tačiau jų parametrų reikšmės dar nėra optimizuojamos. Parametrų inicializavimas, modelio išvesties skaičiavimas ir optimizavimas atliekami vėlesniame modelio mokymo etape.

Tokiu būdu kiekvienam sakiniui gaunama parametrizuota kvantinė grandinė, paruošta vėliau naudoti modelio mokymo etape. Parametrizuotos kvantinės grandinės pavyzdys parodytas pav. 3.

3.5. Kvantinių grandinių filtravimas

Sugeneravus parametrizuotas kvantines grandines, buvo atliekamas papildomas filtravimo etapas. Šio etapo tikslas – pašalinti tas grandines, kurios yra per didelės arba per sudėtingos praktiniam modelio mokymui. Nors tokios grandinės teoriškai gali būti sudarytos iš gramatinių diagramų, jų vykdymas kvantiniame simulatoriuje arba naudojimas mokymo metu gali būti nepraktiškas dėl didelių atminties ir skaičiavimo laiko kainos.

Kiekviena kvantinė grandinė buvo transformuojama į *pytket* formato objektą, kad būtų galima įvertinti jos technines charakteristikas: kubitų skaičių, kvantinių vartų skaičių ir grandinės gylį. Šie

rodikliai leidžia įvertinti, ar grandinė yra tinkama tolesniam modelio mokymui.

Filtravimo metu buvo taikomi šie apribojimai:

- maksimalus kubitų skaičius – 25;
- maksimalus atminties poreikis – 7 GiB;
- maksimalus kvantinės grandinės gylis – 80;
- maksimalus kvantinių vartų skaičius – 3000.

Kubitų skaičiaus limitas yra svarbiausias apribojimas, nes kvantinės būsenos vektoriaus dydis auga eksponentiškai didėjant kubitų skaičiui. Jei naudojamas būsenos vektoriaus simuliacija, n kubitų grandinei reikia saugoti 2^n kompleksinių amplitudžių. Šiame tyrime atminties poreikis buvo apytiksliai vertinamas taip:

$$M = b \cdot 2^n, \quad (11)$$

kur M yra reikalingas atminties kiekis baitais, n – kubitų skaičius, o b – konstanta, priklausantis nuo naudojamos kvantinės būsenos reprezentacijos ir skaitinio tikslumo. Kadangi naudotas dvigubo tikslumo kompleksinių skaičių formatas, vienai amplitudei skirta 16 baitai.

Be kubitų skaičiaus, grandinės buvo filtruojamos ir pagal jos gylį bei vartų skaičių. Net jei grandinė turi santykinai nedaug kubitų, didelis vartų skaičius arba didelis grandinės gylis vis tiek gali reikšmingai sulėtinti modelio mokymą. Dėl šios priežasties tokios grandinės taip pat buvo pašalinamos iš tolesnio apdorojimo.

Jeigu bent vienas iš nurodytų apribojimų buvo viršytas, atitinkama grandinė buvo laikoma netinkama mokymui ir pašalinama iš duomenų rinkinio. Kartu buvo išsaugomas pašalintos grandinės indeksas ir klaidos priežastis. Tai leido stebėti, kiek duomenų prarandama dėl techninių apribojimų ir kokie apribojimai dažniausiai lemia sakinių pašalinimą.

Filtravimo etapas yra dar vienas praktinis kompromisas. Jis sumažina galutinį mokymo duomenų kiekį, tačiau užtikrina, kad į modelio mokymą patektų tik tokios kvantinės grandinės, kurios gali būti realistiškai apdorotos naudojamoje skaičiavimo aplinkoje. Taip sumažinama atminties klaidų tikimybė ir stabilizuojamas modelio mokymo procesas.

4. Kvantinis modelis

Šiame darbe ekstraktyvus santraukų sudarymas formuluojamas kaip dvejetainės sakinių klasifikacijos uždavinys. Tai reiškia, jog kiekvienam sakiniui modelis turi nustatyti, ar sakinyje turėtų būti įtrauktas į ekstraktyvią santrauką. Todėl kiekviena parametrizuota grandinė atitinka vieną sakinių, o modelio išvestis interpretuojama kaip dviejų klasių prognozė: sakinyje neįtraukiamas arba įtraukiamas į santrauką.

4.1. Modelio realizacija naudojant NumpyModel

Modelio mokymo vykdymui pasirinktas naudoti *lambeq* bibliotekos `NumpyModel`. Šis modelis apskaičiuoja parametrizuotų diagramų išvestis klasikiniu skaitiniu būdu, naudojant NumPy pagrįstus tenzorinius skaičiavimus. Nors pradinė sakinio reprezentacija yra gaunama taikant kvantinį ansatzą, šiuo atveju grandinės nėra vykdomos naudojant mėginių pagrindu atliekamą vykdymą (angl. shot-based execution, toliau – mėginių vykdymas). Vietoje to naudojamas tikslusis parametrizuotų grandinių simulavimas (angl. exact simulation non-shot-based simulation, toliau – tikslusis simulavimas).

Toks pasirinkimas buvo atliktas dėl praktinių priežasčių. Pradiniuose bandymuose buvo nagrinėtas `TketModel` (žr. sąvoką) kartu su `AerSimulator` bei kvantinių grandinių simulavimo aplinka `AerBackend`, tačiau mėginių vykdymas buvo pernelyg jautrus dėl triukšmo (angl. noise), per sudėtingas techninius apribojimus, o mokymo trukmė praktiniams darbo eksperimentams buvo per ilga. Kadangi šiame tyrime pagrindinis tikslas yra įvertinti QNLP reprezentacijos pritaikomumą ekstraktyvaus santraukų sudarymo uždaviniui, o ne tirti konkretaus kvantinio įrenginio ar vykdymo terpės triukšmo savybes, galutiniam mokymui pasirinktas stabilesnis `NumpyModel` variantas.

`NumpyModel` modelis parametrizuotas diagramas įvertina atlikdamas skaitinius tenzorinius skaičiavimus [Qua26b]. Praktiniu požiūriu tai reiškia, kad modelio išvestis apskaičiuojama tiesiogiai iš grandinės arba diagramos matematinės reprezentacijos, o ne aproksimuojama iš baigtinio grandinės vykdymų ir mėginių vykdymo. Todėl tokio tipo išvesties vertinimas nėra priklausomas nuo mėginių vykdymo statistinio triukšmo.

Taigi, naudojant `NumpyModel`, modelio parametrai vis tiek siejami su ansatzo sugeneruotomis parametrizuotomis grandinėmis [Qua26a]. Mokymo metu optimizuojami tie patys simbolių parametrai, kurie atsiranda pritaikius ansatz sakinių diagramoms (žr. poskyrių 3.4). Skirtumas yra toks, jog išvestys apskaičiuojamos ne atliekant mėginių pagrindu vykdomą kvantinės grandinės vertinimą, o naudojant tiesioginį skaitinį parametrizuotų grandinių skaičiavimą.

4.2. Modelio išvestis ir sakinio klasifikavimas

Modelis apskaičiuoja grandinės išvestį klasikiniu būdu, sutraukdamas atitinkamą tenzorinę reprezentaciją, o gautas rezultatas interpretuojamas kaip dviejų klasių prognozės reikšmės. Kitaip sakant, modelis kiekvienam sakiniui pateikia dviejų reikšmių išvestį, atitinkančią dvi galimas

klases. Šiame darbe naudotos etiketės pateikiamos vektoriniu formatu:

$$[1, 0]$$

neigiamai klasei, kai sakiny s nėra įtraukiamas į santrauką, ir

$$[0, 1]$$

teigiamai klasei, kai sakiny s ekstraktyviai santraukai laikomas tinkamu .

Modelio prognozė interpretuojama pasirenkant didesnę išvesties reikšmę. Jeigu antroji reikšmė yra didesnė už pirmąją, sakiny s priskiriamas teigiamai klasei; priešingu atveju jis priskiriamas neigiamai klasei. Tokiu būdu kvantinis modelis veikia kaip sakinių klasifikatorius, kurio užduotis yra išmokti atskirti sakinius, kurie galėtų tapti ekstraktyvios santraukos dalimi.

Šiame darbe modelis vadinamas kvantiniu ta prasme, kad sakiniai reprezentuojami per kvantinio ansatzo sugeneruotas parametrizuotas grandines. Tačiau galutinis šių grandinių vykdymas atliekamas klasikiniu skaitiniu būdu, naudojant NumpyModel. Todėl ši realizacija turėtų būti suprantama kaip kvantinės modelio architektūros klasikinė simuliacija, o ne vykdymas tikrajame kvantiniame įrenginyje.

4.3. TketModel ir AerSimulator atsisakymo pagrindimas

Pradiniuose eksperimentuose buvo nagrinėta galimybė naudoti TketModel kartu su AerSimulator bei AerBackend. Šis metodas yra artimas kvantinių grandinių vykdymo interpretacijai, nes leidžia naudoti kvantinės vykdymo aplinkos simuliaciją ir kubitų matavimų statistiką. Vis dėlto, praktiniuose bandymuose pastebėta, jog dalis išvesčių buvo neinformatyvios klasifikavimo požiūriu, pavyzdžiui, abi klasės gaudavo vienodas arba net nulines reikšmes. Tokios išvestys yra problemiškos, nes dviejų klasių klasifikavimo uždavinyje modelio rezultatas turi būti interpretuojamas kaip sprendimas tarp neigiamos ir teigiamos klasės. Kai modelis grąžina nulinį vektorius, išvestis tampa neinformatyvi ir negali būti interpretuojama kaip prasminga klasės prognozė. Dėl to modelio mokymas buvo stipriai nestabilus ir lėtas, be to – neprognozuojamas. Metrikos tampa nepatikimos, nes dalis prognozių neatspindi realaus klasifikavimo sprendimo. Dėl šios priežasties galutiniam mokymo etapui pasirinktas NumpyModel, leidžiantis stabiliau įvertinti parametrizuotų diagramų išvestis.

Toks pasirinkimas nereiškia, kad atsisakoma QNLP modelio struktūros; atsisakoma tik kvantinių matavimų vykdymo su simuliuotais kubitais šiame eksperimente.

5. Modelio mokymas

Modelio mokymas atliktas naudojant *lambeq* bibliotekos `QuantumTrainer`. Jam buvo perduotas `NumpyModel` modelis, dvejetainės kryžminės entropijos nuostolio funkcija ir SPSA. `NumpyModel` buvo atsakingas už parametrizuotų diagramų išvesčių apskaičiavimą, o `QuantumTrainer` valdė mokymo ciklą: duomenų pateikimą paketais (angl. *batches*), nuostolio funkcijos taikymą, optimizatoriaus iškvietimą ir vertinimo metrikų skaičiavimą.

Aukšto lygmens modelio mokymo eiga buvo tokia:

1. kiekvienos epochos metu `QuantumTrainer` pateikia mokymo duomenis modeliui;
2. `NumpyModel` apskaičiuoja prognozes;
3. pagal prognozes ir tikrąsias etiketes `BinaryCrossEntropyLoss` apskaičiuoja nuostolio reikšmę;
4. `SPSAOptimizer`, naudodamas nuostolio funkcijos įverčius, atnaujinama modelio parametrai.

Šiame tyrime modelio mokymas suprantamas kaip parametrizuotų grandinių parametrų optimizavimo procesas. Mokymo metu SPSA optimizatorius keičia modelio parametrai taip, kad būtų mažinama pasirinkta nuostolio funkcija. Todėl toliau tekste sąvoka „parametrų optimizavimas“ vartojama kalbant apie konkrečią mokymo proceso dalį, kurioje atnaujinami modelio parametrai.

5.1. Modelio paruošimas mokymui

Prieš pradėdant mokymą, `NumpyModel` modelio objektas sukuriama iš visų mokymui validavimui ir testavimui naudojamų parametrizuotų diagramų. Tam buvo naudojamas metodas `NumpyModel.from_diagrams()`, kuris surenka diagramose esančius simbolinius parametrus ir pagal juos paruošia modelio parametrų vektorius. Tai yra būtina – modelis turi identifikuoti visus simbolinius parametrus, esančius diagramose. Jeigu vėliau modeliui pateikiama diagrama su dar nematytu simboliu, modelis gali neturėti šiam simboliui priskirtos parametro reikšmės, tuomet yra metama klaida ir modelio mokymas bei testavimas nebegali įvykti.

Dėl tokios priežasties modelio inicializavimo metu buvo naudojamos visos grandinės, kurios galėjo būti pateiktos mokymo, validavimo arba testavimo etapuose. Inicializavimo metu modelis gauna tik diagramų struktūrą ir simbolinius parametrus, bet ne sakinių etikečių informaciją. Vis dėlto, tai nereiškia, kad modelis iš anksto gauna atsakymus iš validavimo ar testavimo rinkinių; jis tik paruošiamas visiems galimiems simboliniams parametrų.

Po modelio sukūrimo parametrai inicializuojami naudojant:

```
model.initialise_weights()
```

Šio žingsnio metu modelio parametrų suteikiamos pradinės reikšmės, kurios vėliau optimizuojamos mokymo metu.

5.2. Mokymo ir vertinimo duomenų rinkiniai

Mokymo metu naudotos trys duomenų dalys: mokymo, validavimo ir testavimo rinkiniai. Mokymo rinkinys buvo naudojamas modelio parametrų optimizuoti, validavimo rinkinys – modelio veikimui stebėti mokymo metu, o testavimo rinkinys – galutiniam modelio įvertinimui po mokymo.

Kadangi mokymo ir vertinimo rinkiniai buvo sudaryti taikant skirtingas sakinių atrankos strategijas, jų etikečių pasiskirstymas skyrėsi. Mokymo rinkinyje buvo siekiama labiau subalansuoto teigiamų ir neigiamų pavyzdžių santykio, kad modelis gautų pakankamai teigiamos klasės pavyzdžių. Tuo tarpu validavimo ir testavimo rinkiniuose išlaikytas konservatyvesnis teigiamų sakinių kiekis, geriau atitinkantis ekstraktyvaus santraukų sudarymo prielaidą, kad į santrauką patenka tik dalis dokumento sakinių. Plačiau apie naudotą duomenų rinkinių sudarymo principą aprašyta poskyryje 2.5.

Eksperimentuose naudoti du galutiniai duomenų rinkinių variantai, kurie skyrėsi pagal `AtomicType.NOUN` tipui priskirtą kubitų skaičių. Vieno kubito konfigūracijos duomenų rinkinys naudotas pagrindiniams modelio mokymo bandymams, o dviejų kubitų `AtomicType.NOUN` konfigūracijos rinkinys (toliau – kubitų konfigūracija) – palyginamajam eksperimentui. Kadangi skirtingas kubitų paskirstymas keičia sugeneruotų kvantinių grandinių dydį, po grandinių filtravimo abiejų konfigūracijų galutiniai mokymo, validavimo ir testavimo rinkiniai nėra identiški.

Konfigūracija	Rinkinys	Sakinių sk.	Teigiamos	Neigiamos	Vid. kubitų sk.
1 kubito	Mokymo	1883	884 (46,95%)	999 (53,05%)	11,27
1 kubito	Validavimo	325	80 (24,62%)	245 (75,38%)	11,23
1 kubito	Testavimo	263	78 (29,66%)	185 (70,34%)	11,23
2 kubitų	Mokymo	1906	964 (50,58%)	942 (49,42%)	14,27
2 kubitų	Validavimo	377	111 (29,44%)	266 (70,56%)	13,60
2 kubitų	Testavimo	431	130 (30,16%)	301 (69,84%)	13,60

3 lentelė. Modelio mokymui, validavimui ir testavimui naudotų rinkinių charakteristikos

5.3. Mokymo konfigūracija

Eksperimentuose buvo naudotos kelios modelio mokymo konfigūracijos. Jos skyrėsi pagal du pagrindinius aspektus: kvantinės reprezentacijos dydį ir optimizatoriaus hiperparametrus. Kvantinės reprezentacijos dydis buvo keičiamas priskiriant skirtingą kubitų skaičių `AtomicType.NOUN` tipui, o optimizavimo eiga buvo valdoma keičiant SPSA hiperparametrus.

Kadangi `AtomicType.SENTENCE` ir `AtomicType.NOUN` tipų kubitų paskirstymo principas jau aprašytas poskyryje 3.4.1, šiame poskyryje akcentuojamos tik eksperimentiškai lygintos konfigūracijos. Pagrindinėje konfigūracijoje sakinio tipui ir daiktavardžio tipui buvo skirta po vieną kubitą:

AtomicType.SENTENCE: 1

AtomicType.NOUN: 1

Antrojoje konfigūracijoje sakinio tipui paliktas vienas kubitas, tačiau daiktavardžio tipui skirti du kubitai:

AtomicType.SENTENCE: 1

AtomicType.NOUN: 2

Šių konfigūracijų palyginimas leidžia įvertinti, kaip didesnė daiktavardinio tipo reprezentacinė erdvė veikia modelio mokymą ir galutinius klasifikavimo rezultatus. Vieno kubito konfigūracija sudaro paprastesnes kvantines grandines ir mažina optimizavimo sudėtingumą. Tuo tarpu dviejų kubitų konfigūracija teoriškai leidžia daiktavardiniam tipams turėti didesnę reprezentacinę erdvę, tačiau kartu padidina sudaromų grandinių kubitų skaičių, parametrų kiekį ir skaičiavimo sudėtingumą. Dėl šios priežasties dviejų kubitų konfigūracija Šiame tyrime vertinama ne kaip tiesioginis patobulinimas, o kaip alternatyvus modelio sudėtingumo didinimo bandymas.

Galutiniuose eksperimentuose vieno kubito konfigūracija buvo naudojama keliuose mokymo bandymuose, keičiant optimizatoriaus hiperparametrus. Dviejų kubitų konfigūracija buvo naudota kaip palyginamasis eksperimentas, leidžiantis įvertinti, ar didesnė reprezentacinė erdvė pagerina modelio gebėjimą atpažinti santraukai tinkamus sakinius.

5.4. Nuostolio funkcija

Modelio mokymui naudota dvejetainė kryžminės entropijos nuostolio funkcija (angl. *Binary Cross-Entropy Loss*). Ji lygina modelio pateiktą dviejų klasių išvestį su tikrąja sakinio etike, pateikta vektoriniu formatu. Šiame darbe naudotos etiketės nėra pateikiamos kaip vienas skaliarinis klasės indeksas, bet kaip dviejų elementų vektoriai: $[1,0]$ neigiamai klasei ir $[0,1]$ teigiamai klasei.

Jeigu tikroji etiketė yra $y_i = [y_{i,0}, y_{i,1}]$, o modelio išvestis yra $\hat{y}_i = [\hat{y}_{i,0}, \hat{y}_{i,1}]$, tuomet *lambeq* realizacijoje prognozė pirmiausia stabilizuojama ir normalizuojama:

$$\tilde{y}_{i,c} = \frac{\hat{y}_{i,c} + \epsilon}{\sum_{k=0}^1 (\hat{y}_{i,k} + \epsilon)}. \quad (12)$$

Tuomet nuostolio reikšmė apskaičiuojama taip:

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{c=0}^1 y_{i,c} \log(\tilde{y}_{i,c}), \quad (13)$$

kur N yra sakinių skaičius, c žymi klasės indeksą, $y_{i,c}$ yra tikroji etiketės reikšmė, o $\tilde{y}_{i,c}$ – išlyginta ir normalizuota modelio išvestis. Reikšmė ϵ yra maža teigiama konstanta, naudojama skaitiniam stabilumui užtikrinti, kad nebūtų skaičiuojamas $\log(0)$.

Tokia formulė atitinka *lambeq* bibliotekos `BinaryCrossEntropyLoss` realizaciją, kai `sparse=False`: tiek modelio prognozės, tiek tikrosios etiketės pateikiamos dviejų elementų vektoriais [Qua25].

Nuostolio funkcija 13 pasirinkta todėl, kad nagrinėjamas uždavinys yra dvejetainė klasifikacija: kiekvienas sakiny priskiriamas vienai iš dviejų klasių – neįtraukiamas arba įtraukiamas į santrauką.

5.5. Optimizavimo metodas

Parametrų optimizavimui naudotas `SPSAOptimizer` (toliau – SPSA). SPSA metodas aproksimuoja nuostolio funkcijos gradientą, atsitiktinai pritaikydamas mažus pokyčius visam parametrų vektoriui. Jis yra praktiškas pasirinkimas parametrizuotoms kvantinėms grandinėms, nes gali optimizuoti modelį tiesiogiai pagal nuostolio funkcijos reikšmes, nereikalaudamas analitinio gradientų apskaičiavimo.

Pagal apskaičiuotas nuostolio reikšmes SPSA atnaujinama modelio parametrus. Taip palaipsniui siekiama sumažinti skirtumą tarp modelio prognozių ir sakiniams priskirtų etikečių.

Svarbi SPSA savybė yra ta, kad gradientui aproksimuoti pakanka dviejų nuostolio funkcijos įvertinimų, nepriklausomai nuo optimizuojamų parametrų skaičiaus [Spa98]. Dėl to metodas yra tinkamas parametrizuotoms kvantinėms grandinėms, kuriose parametrų skaičius gali būti didelis, o analitinis gradientų skaičiavimas nėra patogus.

Tyrime buvo keičiami trys pagrindiniai SPSA hiperparametrai: a , c ir A . Parametras a valdo mokymosi žingsnio dydį, t. y. kiek stipriai modelio parametrai keičiami kiekvieno optimizavimo žingsnio metu. Didesnė a reikšmė gali paspartinti mokymą, tačiau taip pat gali padidinti nuostolio funkcijos svyravimus arba lemti nestabilų konvergavimą. Mažesnė a reikšmė lemia atsargesnius parametrų atnaujinimus, tačiau mokymas vyksta lėčiau, arba gali iš viso nebevykti.

Parametras c nusako perturbacijos dydį. Jis apibrėžia, koku mastu parametrų vektorius laikinai pakeičiamas teigiama ir neigiama kryptimi, siekiant įvertinti nuostolio funkcijos pokytį. Jeigu c reikšmė per maža, nuostolio pokyčio įvertis gali tapti jautrus skaitiniam triukšmui. Jeigu c reikšmė per didelė, optimizatoriai gali vertinti pernelyg nutolusias parametro reikšmes ir gauti mažiau tikslių lokalių optimizavimo kryptį.

Parametras A naudojamas mokymosi žingsnio stabilizavimui ankstyvose optimizavimo iteracijose. Jis nurodo kaip greitai mažėja efektyvus mokymosi žingsnis optimizavimo metu. Didesnė A reikšmė gali padaryti mokymo pradžią stabilesnę, nes pradiniai žingsniai tampa mažiau agresyviūs. Mažesnė A reikšmė leidžia SPSA greičiau reaguoti į nuostolio funkcijos pokyčius, tačiau gali padidinti mokymo kreivės svyravimus.

Kadangi SPSA optimizatoriai remiasi stochastinėmis perturbacijomis, skirtingos a , c ir A reikšmės gali turėti reikšmingą poveikį mokymo stabilumui, konvergavimas ir galutiniams vertinimo rezultatams. Todėl šiame darbe buvo atlikti keli mokymo bandymai su skirtingomis šių hiperparametrų reikšmėmis. Galutiniai kiekvienos konfigūracijos rezultatai pateikiami rezultatų skyriuje.

Parametras	Reikšmė mokymo procese
a	Mokymosi žingsnio dydis. Didesnė reikšmė lemia stipresnius parametrų atnaujinimus, tačiau gali didinti mokymo nestabilumą.
c	Perturbacijos dydis, naudojamas nuostolio funkcijos pokyčiui įvertinti aplink esamą parametrų vektorių.
A	Stabilizavimo parametras, veikiantis mokymosi žingsnio mažėjimą ankstyvose optimizavimo iteracijose.

4 lentelė. SPSAOptimizer hiperparametrų reikšmė mokymo procese

5.6. Vertinimo eiga

Mokymo proceso metu buvo skaičiuojama ne tik nuostolio funkcijos reikšmė, bet ir papildomos vertinimo metrikos: tikslumas, subalansuotas tikslumas, preciziškumas, jautrumas ir F1 įvertis. Šios metrikos buvo skaičiuojamos tiek su mokymo, tiek su validavimo duomenimis. Toks vertinimas leido stebėti, ar modelio veikimas gerėja tik su mokymo duomenimis, ar pagerėjimas atsispindi ir validavimo rinkinyje.

Eksperimentuose buvo naudojamas mokymo duomenų vertinimas kiekvienos epochos metu. Tai leido palyginti mokymo ir validavimo metrikų kitimą ir įvertinti, ar modelis nepradeda pernelyg prisitaikyti prie mokymo duomenų. Kadangi uždavinys susijęs su nesubalansuota dvejetainės klasifikacijos problema, pagrindinis dėmesys buvo skiriamas ne vien bendram tikslumui, bet ir teigiamos klasės metrikoms – preciziškumui, jautrumui ir F1 įverčiui.

Mokymo metu modelio būseną buvo išsaugojama. Kiekvienam mokymo bandymui buvo saugomas paskutinės epochos modelis ir geriausias modelis pagal validavimo rezultatus. Tai leido vėliau atkurti apmokytą modelį, analizuoti nuostolio funkcijos ir metrikų kitimą bei palyginti skirtingų eksperimentų rezultatus.

Išsaugoti mokymo istorijos duomenys buvo naudojami grafikams sudaryti ir rezultatų analizei atlikti. Testavimo rinkinys nebuvo naudojamas mokymo eigai valdyti; jis taikytas tik galutiniam modelio įvertinimui po mokymo.

5.7. Vertinimo metrikos

Modelio kokybei vertinti naudotos kelios klasifikavimo metrikos: tikslumas, subalansuotas tikslumas, preciziškumas, jautrumas ir F1 įvertis. Kadangi duomenų rinkinyje teigiamų ir neigiamų etikečių santykis nėra visiškai subalansuotas, vien tik bendras tikslumas nėra pakankamas modelio veikimui įvertinti. Dėl šios priežasties papildomai skaičiuotos metrikos, leidžiančios atskirai įvertinti teigiamos klasės atpažinimą.

5 lentelė. Klasifikavimo klaidų matrica

	Prognozuota neigiama	Prognozuota teigiama
Tikroji neigiama	TN	FP
Tikroji teigiama	FN	TP

Tikslumas (angl. *accuracy*) parodo, kokia visų pavyzdžių dalis buvo klasifikuota teisingai:

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (14)$$

kur TP žymi teisingai atpažintus teigiamus pavyzdžius, TN – teisingai atpažintus neigiamus pavyzdžius, FP – klaidingai teigiamai klasifikuotus pavyzdžius, o FN – klaidingai neigiamai klasifikuotus pavyzdžius.

Subalansuotas tikslumas (angl. *balanced accuracy*) apskaičiuoja teigiamos ir neigiamos klasės atpažinimo tikslumo vidurkį:

$$\text{balanced accuracy} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right). \quad (15)$$

Ši metrika naudinga tada, kai klasės pasiskirsčiusios netolygiai, nes ji neleidžia modelio rezultatams atrodyti gerai vien dėl dominuojančios klasės prognozavimo.

Preciziškumas (angl. *precision*) parodo, kokia modelio teigiamai klasifikuotų sakinių dalis iš tikrųjų atitinka ekstraktyvios santraukos sakinius:

$$\text{precision} = \frac{TP}{TP + FP}. \quad (16)$$

Jautrumas (angl. *recall*) parodo, kokią dalį tikrųjų teigiamų pavyzdžių modelis teisingai atpažįsta. Kitaip tariant, ekstraktyvaus santraukų sudarymo uždavinyje ši metrika parodo, kokią reikšmingų sakinių dalį modelis sugeba atrasti:

$$\text{recall} = \frac{TP}{TP + FN}. \quad (17)$$

F1 įvertis (angl. *F1-score*) yra preciziškumo ir jautrumo harmoninis vidurkis:

$$F1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}. \quad (18)$$

Ši metrika naudota kaip bendras teigiamos klasės atpažinimo kokybės rodiklis, nes ji vienu metu įvertina ir tai, kiek modelio atrinktų sakinių buvo teisingi, ir tai, kiek tikrųjų teigiamų sakinių modelis sugebėjo atrasti.

6. Ekperimentų rezultatai

Šiame skyriuje pateikiami skirtingų modelio mokymo šakų rezultatai. Eksperimentai buvo vykdomi iteratyviai: pradinis modelis buvo mokomas su pasirinkta hiperparametrų konfigūracija, o vėliau, remiantis mokymo ir validavimo nuostolio bei metrikų kitimu, buvo pasirenkama: tęsti tos pačios šakos mokymą ar grįžti prie ankstesnio kontrolinio taško ir keisti hiperparametrus. Tokiu būdu modelių mokymas įgavo šakotą struktūrą.

Modelių pavadinimuose naudojamas žymėjimas `vol.x.y`. Pirmasis skaičius nurodo pagrindinę mokymo šaką, o antrasis – tos šakos tęsinį. Pavyzdžiui, `vol.2.3` žymi antrąją pagrindinę šaką ir jos trečiąjį tęsinį.

Kiekvieno mokymo metu QuantumTrainer išsaugojo paskutinės epochos modelį `model.lt` ir geriausią modelio kontrolinį tašką `best_model.lt`. Šiame darbe mokymo ir validavimo kreivės sudaromos naudojant `model.lt`, t.y. visą mokymo istoriją iki paskutinės epochos. Tuo tarpu galutinis modelio vertinimas testavimo rinkinyje atliekamas naudojant `best_model.lt`, nes šis kontrolinis taškas atitinka automatiškai parinktą geriausią konkretaus mokymo bandymo modelio būseną.

Testavimo rezultatai gauti naudojant atitinkamos modelio versijos `best_model.lt` kontrolinį tašką. Tokiu būdu grafikuose parodomas visas modelio mokymo progresas, o testavime – to modelio geriausio varianto rezultatas.

Taip pat testavimo rezultatuose taikomi du klasės parinkimo principai: `argmax` ir slenkstinis parinkimas su 0,7 reikšme. `argmax` principas parenka tą klasę, kurios modelio išvesties reikšmė yra didesnė. Kadangi šiame tyrime modelio išvestis yra dviejų elementų vektorius, `argmax` leidžia tiesiogiai įvertinti, kurią iš dviejų klasių modelis laiko labiau tikėtina: sakinyš neįtraukiamas arba įtraukiamas į santrauką. Todėl `argmax` vertinimas šiame darbe naudojamas kaip bendras modelio klasifikavimo gebėjimo įvertinimas.

Papildomai taikomas slenkstinis klasės parinkimas su 0,7 reikšme. Šiuo atveju sakinyš priskiriamas teigiamai klasei tik tada, kai teigiamos klasės išvesties reikšmė pasiekia nustatytą slenkstį. Toks vertinimas yra griežtesnis, nes modelis turi būti labiau užtikrintas prieš priskirdamas sakinių santraukai. Tai yra aktualu ekstraktyvaus santraukų sudarymo uždavinyje, nes į santrauką įprastai patenka tik nedidelė dokumento sakinių dalis. Todėl slenkstinis parinkimas šiame darbe interpretuojamas kaip praktiškesnis sakinių atrankos scenarijus, o `argmax` – kaip bendresnis dvejetainės klasifikacijos vertinimas.


Šių dviejų principų rezultatai interpretuojami kartu: `argmax` parodo, kiek modelis geba atskirti teigiamą ir neigiamą klasę be papildomo atrankos griežtinimo, o slenkstinis parinkimas parodo, kaip modelio veikimas keičiasi taikant konservatyvesnę sakinių atranką. Tai atitinka validavimo ir testavimo rinkinių sudarymo logiką, aprašytą poskyryje 2.5, kur konservatyvesnis teigiamų sakinių kiekis buvo pasirinktas siekiant realistiškesnio ekstraktyvios santraukos scenarijaus.

6.1. Vieno kubito modelių mokymo rezultatai


6.1.1. Modelis vol.1.1.2

6 lentelė. Modelio vol.1.1.2 mokymo parametrai


Modelis	Epochos	Paketai	a	c	A
vol.0	200	256	0,02	0,08	50
vol.1	300	256	0,02	0,08	30
vol.1.2	500	256	0,02	0,08	30



4 pav. Modelio vol.1.1.2 teigiamos klasės tikslumas, jautrumas ir F1 įvertis



5 pav. Modelio vo1.1.2 mokymo ir validavimo nuostoliai



6 pav. Modelio vo1.1.2 tikslumas ir subalansuotas tikslumas

7 lentelė. Modelio vo1.1.2 testavimo rezultatai naudojant best_model.1t kontrolinį tašką

Metrika	argmax	Slenkstinis parinkimas 0,7
Tikslumas	0,5171	0,6312
Subalansuotas tikslumas	0,5047	0,5302
BCE nuostolis	1,0471	1,0471
Preciziškumas	0,3008	0,3492
Jautrumas	0,4744	0,2821
F1 įvertis	0,3682	0,3121

8 lentelė. Modelio vo1.1.2 testavimo klaidų matricos reikšmės

Vertinimo būdas	TP / FP	FN / TN
argmax	37 / 86	41 / 99
Slenkstis 0,7	22 / 41	56 / 144

Modelio vo1.1.2 mokymo ir validavimo nuostolio kreivės (žr. pav. 5) rodo nuoseklų nuostolio mažėjimą. Mokymo nuostolis mažėjo beveik viso mokymo metu, o validavimo nuostolis mažiausią reikšmę pasiekė apie 417 epochą. Po šio taško validavimo nuostolio gerėjimas tapo nežymus, todėl tolimesnis tos pačios šakos mokymas turėjo ribotą praktinę naudą.

Tikslumo ir subalansuoto tikslumo kreivės (žr. pav. 6) rodo, kad bendras validavimo tikslumas išliko apie 0,54, tačiau validavimo subalansuotas tikslumas buvo tik šiek tiek didesnis už 0,50. Tai rodo, kad modelis nebuvo vien tik daugumos klasės klasifikatorius, bet jo gebėjimas atskirti abi klases išliko stipriai ribotas. Kadangi validavimo ir testavimo rinkiniuose dominuoja neigiama klasė, bendras tikslumas nėra pakankamas modelio kokybės rodiklis.

Teigiamos klasės metrikos (žr. pav. 4) taip pat rodo ribotą modelio veikimą. Validavimo F1 įvertis neviršijo maždaug 0,34, o preciziškumas išliko žemas. Tai reiškia, kad modelis sugebėjo aptikti dalį santraukai priskirtų sakinių, tačiau gana dažnai teigiamai klasifikavo ir tuos sakinius, kurie pagal etiketes neturėjo būti įtraukti į santrauką.

Testavimo rinkinyje (žr. 7 lentelę), naudojant argmax, modelis pasiekė 0,5171 tikslumą, 0,5047 subalansuotą tikslumą ir 0,3682 F1 įvertį. Šie rezultatai yra mažesni už daugumos klasės bazinį tikslumą, kuris šiame testavimo rinkinyje siekia 0,7034, todėl modelio praktinis veiksmingumas išliko ribotas. Slenkstinis 0,7 parinkimas padidino bendrą tikslumą iki 0,6312 ir preciziškumą iki 0,3492, tačiau sumažino jautrumą iki 0,2821 ir F1 įvertį iki 0,3121. Todėl šiam modeliui pagrindiniu palyginimo rezultatu laikomas argmax vertinimas.

Kadangi po maždaug 400 epochų validavimo nuostolio gerėjimas sulėtėjo, o klasifikavimo metrikos išliko artimos atsitiktinio klasifikavimo lygiui, ši šaka nebuvo toliau tęsiama ta pačia konfigūracija. Vietoje to buvo grįžta prie ankstesnio mokymo taško ir išbandytos kitos hiperparametrų

kombinacijos, siekiant patikrinti, ar kitoks mokymosi žingsnis arba paketo dydis gali pagerinti modelio generalizaciją.


6.1.2. Modelis vol.2.2

9 lentelė. Modelio vol.2.2 mokymo šaka


Modelis	Epochos	Batch	a	c	A
vol.0	200	256	0,02	0,08	50
vol.2	350	256	0,04	0,08	30
vol.2.2	400	128	0,02	0,08	30



7 pav. Modelio vol.2.2 teigiamos klasės tikslumas, jautrumas ir F1 įvertis



8 pav. Modelio vo1.2.2 mokymo ir validavimo nuostoliai



9 pav. Modelio vo1.2.2 tikslumas ir subalansuotas tikslumas

10 lentelė. Modelio `vol.2.2` testavimo rezultatai naudojant `best_model.lt` kontrolinį tašką

Metrika	argmax	Slenkstinis parinkimas 0,7
Tikslumas	0,5285	0,6350
Subalansuotas tikslumas	0,5166	0,5329
BCE nuostolis	1,0506	1,0506
Preciziškumas	0,3115	0,3548
Jautrumas	0,4872	0,2821
F1 įvertis	0,3800	0,3143

11 lentelė. Modelio `vol.2.2` testavimo klaidų matricos reikšmės

Vertinimo būdas	TP / FP	FN / TN
argmax	38 / 84	40 / 101
Slenkstis 0,7	22 / 40	56 / 145

Modelis `vol.2.2` buvo sudarytas kaip atsakas į ankstesnės `vol.1.1.2` šakos ribotą gerėjimą. Pradinė `vol.0` konfigūracija naudojo $a = 0,02$, $c = 0,08$, $A = 50$ ir `batch_size = 256`. Vėlesnėje `vol.2` šakoje SPSA mokymosi žingsnio parametras a buvo padidintas iki 0,04, siekiant patikrinti, ar agresyvesni parametų atnaujinimai pagerina modelio konvergenciją. Galiausiai `vol.2.2` šakoje a reikšmė grąžinta į 0,02, o paketo dydis sumažintas iki 128. Tokiu būdu buvo siekiama išlaikyti atsargesnį parametų atnaujinimą, bet padidinti atnaujinimų dažnumą mažesniais duomenų paketais.

Modelio mokymo ir validavimo nuostolio kreivės (žr. pav. 8) rodo, kad mokymo nuostolis mažėjo beveik viso mokymo metu. Validavimo nuostolis taip pat mažėjo pirmoje mokymo dalyje, tačiau mažiausią reikšmę pasiekė apie 302 epochą, o vėliau pradėjo nežymiai didėti. Tai rodo, kad vėlesnėse epochose modelis vis labiau prisitaikė prie mokymo rinkinio, tačiau papildoma nauda validavimo duomenims tapo ribota.

Tikslumo ir subalansuoto tikslumo grafikas (žr. pav. 9) rodo, kad bendras validavimo tikslumas buvo šiek tiek didesnis negu ankstesnėje `vol.1.1.2` šakoje, tačiau validavimo subalansuotas tikslumas vis tiek išliko tik nedaug didesnis už 0,50. Tai reiškia, kad pakeista hiperparametų kombinacija pagerino modelio rezultatą, bet nepašalino pagrindinės problemos – riboto gebėjimo atskirti abi klases konservatyvesniame validavimo rinkinyje.

Teigiamos klasės metrikos (žr. pav. 7) rodo nežymų pagerėjimą, palyginti su `vol.1.1.2` modeliu, tačiau validavimo F1 įvertis išliko apie 0,33–0,34, o preciziškumas vis dar buvo žemas.

Testavimo rinkinyje, naudojant `argmax`, modelis pasiekė 0,5285 tikslumą, 0,5166 subalansuotą tikslumą ir 0,3800 F1 įvertį. Šie rezultatai taip pat yra šiek tiek geresni negu `vol.1.1.2` modelio rezultatai, tačiau išlieka mažesni už didžiausios klasės bazinį tikslumą. Slenkstinis 0,7 parinkimas padidino bendrą tikslumą iki 0,6350 ir preciziškumą iki 0,3548, tačiau sumažino jautrumą iki


0,2821 ir F1 įvertį iki 0,3143. Todėl pagrindiniam modelių palyginimui svarbesnis išlieka argmax rezultatas.

Apibendrinant, vol. 2.2 šaka parodė, kad hiperparametrų keitimas gali nežymiai pagerinti testavimo rezultatus, ypač teigiamos klasės F1 įvertį. Vis dėlto validavimo ir testavimo metrikos išliko artimos atsitiktinio klasifikavimo lygiui pagal subalansuotą tikslumą, todėl šis modelis laikytinas tik nedideliu pagerėjimu, o ne esminiu kokybės šuoliu.


6.1.3. Modelis vol. 3.3.1.2

12 lentelė. Modelio vol. 3.3.1.2 mokymo šaka


Modelis	EPOCHOS	Paketo dydis	a	c	A
vol. 0	200	256	0,02	0,08	50
vol. 3	300	128	0,03	0,08	80
vol. 3.3	350	128	0,05	0,08	80
vol. 3.3.1	400	128	0,05	0,06	80
vol. 3.3.1.2	500	128	0,06	0,06	100



10 pav. Modelio vol. 3.3.1.2 teigiamos klasės tikslumas, jautrumas ir F1 įvertis



11 pav. Modelio vo1.3.3.1.2 mokymo ir validavimo nuostoliai



12 pav. Modelio vo1.3.3.1.2 tikslumas ir subalansuotas tikslumas

13 lentelė. Modelio `vo1.3.3.1.2` testavimo rezultatai naudojant `best_model.1t` kontrolinį tašką

Metrika	argmax	Slenkstinis parinkimas 0,7
Tikslumas	0,5095	0,6312
Subalansuotas tikslumas	0,4993	0,5339
BCE nuostolis	1,0438	1,0438
Preciziškumas	0,2960	0,3538
Jautrumas	0,4744	0,2949
F1 įvertis	0,3645	0,3217

14 lentelė. Modelio `vo1.3.3.1.2` testavimo klaidų matricos reikšmės

Vertinimo būdas	TP / FP	FN / TN
argmax	37 / 88	41 / 97
Slenkstis 0,7	23 / 42	55 / 143

Modelis `vo1.3.3.1.2` buvo sudarytas tęsiant vieno kubito konfigūracijos mokymą iš `vo1.3` šakos. Šioje šakoje buvo nuosekliai keičiami SPSA hiperparametrai: pirmiausia padidintas mokymosi žingsnio parametras a , vėliau sumažintas perturbacijos parametras c , o paskutinėje šakos dalyje padidintas stabilizavimo parametras A . Tokiu būdu buvo siekiama patikrinti, ar aktyvesni parametų atnaujinimai, kartu su mažesne perturbacija ir didesniu stabilizavimu, gali pagerinti modelio mokymosi eigą.

Modelio mokymo ir validavimo nuostolio kreivės (žr. pav. 11) rodo aiškų nuostolio mažėjimą. Mokymo ir validavimo nuostoliai mažėjo. Vis dėlto po maždaug 420 epochų mokymo nuostolis toliau mažėjo, o validavimo nuostolis pradėjo stabilizuotis. Tai rodo, kad vėlesnis mokymas labiau gerino prisitaikymą prie mokymo duomenų ir validavimo rinkinyje papildoma nauda tapo ribota.

Tikslumo ir subalansuoto tikslumo grafikas (žr. pav. 12) rodo, kad šio modelio mokymo metrikos kilo aiškiau negu ankstesnėse šakose. Validavimo subalansuotas tikslumas taip pat pakilo aukščiau nei modeliuose `vo1.1.2` ir `vo1.2.2`, tačiau vis tiek išliko tik šiek tiek didesnis už atsitiktinio klasifikavimo lygį. Tai reiškia, kad modelis rodė geresnę validavimo dinamiką, bet klasių atskyrimas išliko ribotas.

Teigiamos klasės metrikos (žr. pav. 10) yra svarbiausias šios šakos pagerėjimas. Validavimo F1 įvertis mokymo pabaigoje pakilo iki maždaug 0,35, o validavimo jautrumas pasiekė apie 0,50. Tai rodo, kad modelis geriau aptiko teigiamos klasės sakinius, palyginti su ankstesnėmis šakomis. Vis dėlto validavimo preciziškumas išliko žemas, todėl dalis teigiamų prognozių vis dar buvo klaidingos.

Testavimo rinkinyje, naudojant `argmax`, modelis pasiekė 0,5095 tikslumą, 0,4993 subalansuotą tikslumą ir 0,3645 F1 įvertį. Nors pagal validavimo grafikus ši šaka atrodė stipriausia, testavimo

rezultatai nepagerino `vol.2.2` modelio rezultato. Tai rodo, kad geresnės validavimo metrikos nevisiškai persikėlė į testavimo rinkinį. Modelis vis dar buvo linkęs per dažnai prognozuoti teigiamą klasę.

Slenkstinis 0,7 parinkimas sumažino teigiamai klasifikuotų sakinių skaičių iki 65 ir padidino bendrą tikslumą iki 0,6312 bei subalansuotą tikslumą iki 0,5339. Taip pat padidėjo preciziškumas iki 0,3538. Jautrumas sumažėjo iki 0,2949, o F1 įvertis – iki 0,3217. Todėl, kaip ir ankstesniuose modeliuose, slenkstinis parinkimas sumažino FP prognozių kiekį, tačiau kartu pablogino teigiamos klasės aptikimą.

Apibendrinant, `vol.3.3.1.2` šaka parodė geriausią modelio mokymo, naudojant vieno kubitų duomenų rinkinius, dinamiką pagal validavimo kreives, ypač pagal teigiamos klasės F1 įvertį. Tačiau testavimo rinkinyje šis pagerėjimas nebuvo patvirtintas: naudojant `argmax`, subalansuotas tikslumas išliko apie 0,50, o F1 įvertis buvo mažesnis negu `vol.2.2` modelio. Slenkstinis 0,7 parinkimas pagerino bendrą ir subalansuotą tikslumą, tačiau sumažino jautrumą ir F1 įvertį. Todėl šią šaką galima laikyti kaip svarbiu hiperparametrų tyrimo etapu, bet ne geriausiu galutiniu modeliu pagal `argmax` testavimo rezultatus.


6.2. Dviejų kubitų konfigūracijos modelio mokymo rezultatai

6.2.1. Modelis `ver.2.1.1.1`


Modelis	EPOCHOS	Paketo dydis	a	c	A
<code>ver.2</code>	100	128	0,05	0,08	80
<code>ver.2.1</code>	200	128	0,04	0,08	80
<code>ver.2.1.1</code>	300	128	0,04	0,06	100
<code>ver.2.1.1.1</code>	400	128	0,03	0,06	80

15 lentelė. Dviejų kubitų konfigūracijos modelio `ver.2.1.1.1` mokymo šaka


13 pav. Modelio ver .2.1.1.1 teigiamos klasės tikslumas, jautrumas ir F1 įvertis



14 pav. Modelio ver .2.1.1.1 mokymo ir validavimo nuostoliai



15 pav. Modelio ver .2.1.1.1 tikslumas ir subalansuotas tikslumas



Metrika	argmax	Slenkstinis parinkimas 0,7
Tikslumas	0,5452	0,6288
Subalansuotas tikslumas	0,5586	0,5550
BCE nuostolis	1,1067	1,1067
Preciziškumas	0,3500	0,3810
Jautrumas	0,5923	0,3692
F1 įvertis	0,4400	0,3750

16 lentelė. Dviejų kubitų konfigūracijos modelio ver .2.1.1.1 testavimo rezultatai naudojant best_model.lt kontrolinį tašką

Vertinimo būdas	TP / FP	FN / TN
argmax	77 / 143	53 / 158
Slenkstinis parinkimas 0,7	48 / 78	82 / 223

17 lentelė. Dviejų kubitų konfigūracijos modelio ver .2.1.1.1 testavimo klaidų matricos reikšmės

Modelio mokymo ir validavimo nuostolio kreivės (žr. pav.14) rodo aiškų mokymo ir validavimo atotrūkį. Mokymo nuostolis nuosekliai mažėjo, o validavimo – po pradinio sumažėjimo

stabilizavosi ir vėliau net padidėjo. Tai rodo, kad modelis labiau prisitaikė prie mokymo rinkinio, nei validavimo.

Tikslumo ir subalansuoto tikslumo grafikas (žr. pav.15) taip pat rodo panašią tendenciją: mokymo metrikos nuosekliai gerėjo, o validavimo metrikos išliko nepastovios ir po maždaug 150 epochų neberodė aiškaus ilgalaikio gerėjimo. Tai leidžia manyti, kad dviejų kubitų konfigūracija padidino modelio gebėjimą prisitaikyti prie mokymo duomenų, tačiau kartu apsunkino generalizaciją.


Validavimo F1 įvertis išliko 0,37-0,39 tarpe, o validavimo jautrumas buvo aukštesnis negu daugelyje vieno kubitų modelių (žr. pav.13). Tai reiškia, kad dviejų kubitų konfigūracijos modelis geriau aptiko teigiamos klasės sakinius, tačiau preciziškumas išliko žemas, taigi išliko ir klaidingai didelis teigiamų prognozių kiekis.

Testavimo rinkinyje, naudojant argmax , modelis pasiekė 0,5452 tikslumą, 0,5586 subalansuotą tikslumą ir 0,4400 F1 įvertį. Tai yra geriausias teigiamos klasės F1 rezultatas iš nagrinėtų modelių. Modelis teisingai atpažino 77 iš 130 teigiamų sakinių, tačiau kartu neteisingai teigiamai klasifikavo 143 sakinius. Tai rodo, kad modelis buvo jautresnis teigiamai klasei.


Slenkstinis parinkimas su 0,7 reikšme sumažino teigiamai klasifikuotų sakinių skaičių ir padidino preciziškumą nuo 0,3500 iki 0,3810. Tačiau jautrumas sumažėjo nuo 0,5923 iki 0,3692, o F1 įvertis – nuo 0,4400 iki 0,3750. Todėl, kaip ir vieno kubitų modeliuose, griežtesnis slenkstinis parinkimas sumažino klaidingai teigiamų prognozių kiekį, tačiau kartu pablogino teigiamos klasės radimą.

Apibendrinant, dviejų kubitų konfigūracijos modelis pagerino testavimo rezultatus pagal argmax vertinimą, ypač teigiamos klasės F1 įvertį ir subalansuotą tikslumą. Vis dėlto šis pagerėjimas buvo pasiektas kartu su aiškesniu mokymo ir validavimo nuostolio atotrūkiu. Todėl dviejų kubitų konfigūracija šiame tyrime parodė didesnę klasifikavimo potencialą, bet kartu ir didesnę persimokymo bei generalizacijos problemų riziką.

6.3. TketModel bandymas




16 pav. TketModel teigiamos klasės tikslumas, jautrumas ir F1 įvertis




17 pav. TketModel mokymo ir validavimo nuostoliai

Tai buvo pirmasis kvantinio modelio mokymo bandymas buvo atliktas naudojant TketModel ir AerSimulator. Šiuo bandymu buvo siekiama įvertinti, mėginių vykdymo pagrindo modelio (angl. shot-based model) mokymą formuluojamam sakinių klasifikavimo uždaviniui. Po šio bandymo paaiškėjo, kad tokia konfigūracija nėra tinkama pagrindiniams eksperimentams.



18 pav. TketModel tikslumas ir subalansuotas tikslumas



19 pav. TketModel nulinių vektorių prognozių dalys

Mokymo ir validavimo nuostolio kreivės (žr. pav. 17) rodo nestabilų mokymo procesą. Tiek mokymo, tiek validavimo nuostoliai stipriai svyravo, o aiškios ir nuoseklios mažėjimo krypties nebuvo matyti. Iš grafiko negalima teigti, kad modelis stabiliai konvergavo.

Nestabilumas ir svyravimai matomi ir kitų metrikų grafikuose (žr. pav. 18 ir pav. 16).

Svarbiausia šio bandymo problema buvo nulinių vektorių prognozės. Nulinių vektorių prognozių dalies grafikas (žr. pav. 19) rodo, kad tiek mokymo, tiek validavimo rinkiniuose maždaug pusė modelio išvesčių buvo nuliniai vektoriai. Apie nulinių vektorių keliamas problemas plačiau aprašyta 4.3 poskyryje.

Atsižvelgiant į nestabilias mokymo kreives ir didelę nulinių vektorių prognozių dalį, TketModel ir AerSimulator konfigūracijos buvo atsisakyta. Šis bandymas parodė, kad norint atlikti tyrimo užduotį mėginių matavimais pagrįstas scenarijus nebuvo pakankamai stabilus.

Rezultatai

1. Darbe sudaryta QNLP modelio taikymo ekstraktyvaus santraukų sudarymo sakinių klasifikavimo uždaviniui eiga. Ekstraktyvus santraukų sudarymas suformuluotas kaip dvejetainė sakinių klasifikacija, kurioje modelis nustato, ar sakinytis turėtų būti įtrauktas į santrauką.
2. Sudarytas sakinių lygmens duomenų rinkinys, tinkamas QNLP modelio mokymo eksperimentams. Mokymo rinkiniui naudotas labiau subalansuotas etikečių pasiskirstymas, o validavimo ir testavimo rinkiniams – konservatyvesnis atrankos kriterijus.
3. Parengta sakinių transformavimo į QNLP modelio mokymui tinkamas reprezentacijas eiga. Ji apėmė sakinių sintaksinį supaprastinimą, transformavimą į gramatines diagramas, diagramų perrašymą ir normalizavimą, kvantinių grandinių generavimą bei grandinių filtravimą pagal techninius apribojimus.
4. Atliktas pradinis TketModel ir AerSimulator bandymas. Šio bandymo metu užfiksuotas nestabilus mokymo procesas, dideli nuostolio bei metrikų svyravimai ir didelė nulinių vektorių prognozių dalis. Dėl to pagrindiniams eksperimentams pasirinktas NumpyModel.
5. Naudojant NumpyModel, atlikti keli modelio mokymo eksperimentai su skirtingomis mokymo šakomis ir hiperparametrų konfigūracijomis.
6. AtomicType.NOUN:1 konfigūracijos eksperimentuose modelių mokymo ir validavimo nuostolio reikšmės galėjo mažėti, tačiau testavimo rinkinyje klasifikavimo metrikos išliko žemos. Geriausias šios konfigūracijos modelis pagal argmax vertinimą pasiekė 0,3800 teigiamos klasės F1 įvertį.
7. AtomicType.NOUN:2 konfigūracija pasiekė geriausius testavimo rezultatus pagal argmax vertinimą. Šis modelis pasiekė 0,5452 tikslumą, 0,5586 subalansuotą tikslumą, 0,35 preciziškumą, 0,5923 jautrumą ir 0,44 teigiamos klasės F1 įvertį.
8. Slenkstinis klasės parinkimas su 0,7 reikšme sumažino teigiamai klasifikuojamų sakinių skaičių ir padidino preciziškumą, tačiau kartu sumažino jautrumą ir dažniausiai sumažino teigiamos klasės F1 įvertį.
9. Eksperimentuose pastebėta, kad hiperparametrų keitimas turėjo įtakos mokymo eigai. Kai kuriose šakose didesnė SPSA parametro a reikšmė leido modeliui toliau gerinti nuostolio arba validavimo metrikų reikšmes po ankstesnės šakos stagnacijos, tačiau šis poveikis nebuvo vienodas visose konfigūracijose.
10. Darbe nustatytas praktinis *lambeq* modelio taikymo apribojimas: modelis, sukurtas naudojant `from_diagrams()`, gali apdoroti tik tuos simbolinius parametrus, kurie buvo įtraukti modelio inicializavimo metu. Todėl naujų sakinių ar naujų diagramų naudojimas gali būti ribotas, jei jose atsiranda anksčiau nematytų simbolių.

Išvados

1. Darbo tikslas buvo pasiektas: *lambeq* pagrindu sudarytas QNLP modelis buvo pritaikytas ekstraktyvaus santraukų sudarymo sakinių klasifikavimo uždaviniui, o eksperimentai leido nustatyti pagrindinius tokio taikymo praktinius apribojimus.
2. Gauti rezultatai rodo, kad QNLP modelį galima techniškai pritaikyti sakinių atrankos uždaviniui: sakinius galima transformuoti į diagramines ir kvantinių grandinių reprezentacijas, o modelio parametrus galima optimizuoti. Vis dėlto šiame tyrime gauta klasifikavimo kokybė nebuvo pakankama praktiniam ekstraktyvaus santraukų sudarymo taikymui.
3. `AtomicType.NOUN:2` konfigūracija buvo pranašesnė už `AtomicType.NOUN:1` konfigūraciją pagal geriausias testavimo metrikas. Tai leidžia manyti, kad didesnė daiktavardinio tipo reprezentacinė erdvė gali pagerinti teigiamos klasės sakinių aptikimą. Tačiau ši konfigūracija taip pat parodė didesnę atotrūkį tarp mokymo ir validavimo nuostolių, todėl didesnė reprezentacinė erdvė siejama ir su didesne persimokymo bei generalizacijos problemų rizika.
4. `TketModel` ir `AerSimulator` bandymas parodė, kad mėginių vykdymu pagrįstas scenarijus šiame darbe nebuvo praktiškas dėl nestabilių metrikų ir nulinių vektorių prognozių.
5. Kadangi sakinių etiketės buvo sugeneruotos naudojant iš anksto apmokytą klasikinę ekstraktyvaus santraukų sudarymo modelį, šiame darbe gauti rezultatai turi būti interpretuojami kaip modelio gebėjimas atkartoti silpnos priežiūros būdu sudarytą sakinių atranką, o ne žmogaus anotacijomis pagrįsta santraukų kokybė.
6. Vienas pagrindinių metodo apribojimų yra sakinių transformavimo į kvantines reprezentacijas sudėtingumas. Realių tekstų sakinius teko supaprastinti, diagramas perrašyti ir normalizuoti, o dalį grandinių pašalinti pagal techninius apribojimus. Tai rodo, kad QNLP metodų taikymas realistiškesniems tekstiniais duomenimis priklauso ne tik nuo modelio mokymo, bet ir nuo reprezentacijos sudarymo efektyvumo.
7. Hiperparametrų keitimas darė poveikį mokymo eigai, tačiau neleido rasti tokios konfigūracijos, kuri iš esmės išspręstų generalizacijos problemą. Todėl šiame darbe hiperparametrų paieškos rezultatai laikomi praktiniu eksperimentiniu pastebėjimu, o ne galutine optimizavimo taisykle.
8. Tolimesniuose darbuose rekomenduojama tirti platesnes kubitų paskirstymo žemėlapių konfigūracijas. Pavyzdžiui, būtų galima priskirti kubitą `AtomicType.PREPOSITIONAL_PHRASE` tipui. Toks pakeitimas padidintų kvantinių grandinių dydį ir skaičiavimo kainą, tačiau galėtų išsaugoti daugiau semantinės informacijos.
9. Tyrimą taip pat būtų tikslinga pratęsti naudojant naujesnes *lambeq* versijas ir jose prieinamus modelių tipus, pavyzdžiui, `PytorchQuantumModel`. Tai galėtų suteikti lankstesnes mokymo, integravimo ir parametrų optimizavimo galimybes.

10. Apibendrinant, darbas neparodė, kad šiame tyrime naudotas QNLP modelis jau yra praktiškai efektyvus ekstraktyvaus santraukų sudarymo sprendimas. Tačiau jis parodė, kad tokią eksperimentinę eigą galima sudaryti ir įvykdyti, o gauti rezultatai leidžia įvardyti pagrindines kliūtis, kurias reikėtų spręsti tolesniuose QNLP taikymo santraukų sudarymui tyrimuose.

Literatūra

- [CSC10] Bob Coecke, Mehrnoosh Sadrzadeh ir Stephen Clark. Mathematical Foundations for a Compositional Distributional Model of Meaning. *arXiv preprint arXiv:1003.4394*, 2010. URL: <https://arxiv.org/abs/1003.4394>.
- [HHo24] HHousen. distilroberta-base-ext-sum WikiHow checkpoint. <https://huggingface.co/HHousen/distilroberta-base-ext-sum>, 2024.
- [HMY⁺20] Matthew Honnibal, Ines Montani, Sofie Van Landeghem ir Adriane Boyd. spaCy: Industrial-strength Natural Language Processing in Python, 2020. doi: 10.5281/zenodo.1212303.
- [YNM17] Masashi Yoshikawa, Hiroshi Noji ir Yuji Matsumoto. A* CCG Parsing with a Supertag and Dependency Factored Model. *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics*, p.p. 277–287, 2017.
- [KFY⁺21] Dimitri Kartsaklis, Ian Fan, Richie Yeung, Anna Pearson ir k.t. lambeq: An Efficient High-Level Python Library for Quantum NLP. *arXiv preprint arXiv:2110.04236*, 2021.
- [KW18] Mahnaz Koupaei ir William Yang Wang. WikiHow: A Large Scale Text Summarization Dataset, 2018. arXiv: 1810.09305 [cs.CL].
- [Liu19] Yang Liu. PreSumm. <https://github.com/nlpyang/PreSumm>, 2019.
- [LL19] Yang Liu ir Mirella Lapata. Text Summarization with Pretrained Encoders. *arXiv preprint arXiv:1908.08345*, 2019. URL: <https://arxiv.org/abs/1908.08345>.
- [NZG⁺16] Ramesh Nallapati, Bowen Zhou, Caglar Gulcehre, Bing Xiang ir k.t. Abstractive Text Summarization using Sequence-to-sequence RNNs and Beyond. *arXiv preprint arXiv:1602.06023*, 2016.
- [Qua25] Quantinuum. lambeq.training.loss source code. https://docs.quantinuum.com/lambeq/_modules/lambeq/training/loss.html, 2025.
- [Qua26a] Quantinuum. lambeq machine learning use cases. https://docs.quantinuum.com/lambeq/guide/ml_use-cases.html, 2026.
- [Qua26b] Quantinuum. lambeq NumpyModel source code. https://docs.quantinuum.com/lambeq/_modules/lambeq/training/numpy_model.html, 2026.
- [Spa98] James C. Spall. AN OVERVIEW OF THE SIMULTANEOUS PERTURBATION METHOD FOR EFFICIENT OPTIMIZATION. *Johns Hopkins Apl Technical Digest*, 19:482–492, 1998. URL: <https://api.semanticscholar.org/CorpusID:7988308>.
- [Ste00] Mark Steedman. *The Syntactic Process*. MIT Press, 2000.

Priedas Nr. 1

Darbo programinio kodo ir vykdymo aplinkos nuorodos

Darbo programinis kodas pateiktas *GitHub* repozitorijoje:

<https://github.com/Green-255/QLPModelTraining.git>

Modelio mokymo kodas pateiktas *Google Colab* aplinkoje:

<https://drive.google.com/file/d/1DGsCmA9WEIAe7mSj9KhbQAUmHp0J8xjh/view?usp=sharing>